

南京大学

大数据技术及应用

期末作业报告

城市住房市场价格形成与分化研究

——基于杭州、金华、临沂的实证分析

姓 名： Qizest

学 院： 工程管理学院

日 期： 2026 年 7 月

2026 年 7 月

目录

1	引言与研究设计	2
1.1	研究背景	2
1.2	研究问题	2
2	数据爬取与清洗	3
2.1	数据爬取思路	3
2.2	数据清洗与填充思路	5
2.3	工作流程与技术路线	10
3	特征工程	11
4	探索性分析	13
4.1	小区级别数据画像	13
4.2	房源级别数据画像	18
4.3	变量相关性与方差分析	30
5	聚类分析	43
5.1	聚类思路与研究问题	43
5.2	特征选择与检验	43
5.3	聚类方法与结果分析	46
6	回归分析	55
6.1	回归思路与研究问题	55
6.2	特征选择与检验	55
6.3	回归模型与分析	60
7	预测模型	66
7.1	预测思路与模型设定	66
7.2	预测性能对比	68
7.3	特征重要性分析	68
7.4	小结	69
8	总结与展望	70
8.1	研究工作总结	70
8.2	研究问题解答	71
8.3	研究局限与反思	72

1 引言与研究设计

1.1 研究背景

安居客作为中国领先的房地产信息服务平台，汇集了海量的房源挂牌数据，为研究城市住房市场提供了丰富的微观数据基础。近年来，随着大数据技术的发展，基于在线房产平台数据的城市住房研究已成为计算社会科学和城市经济学的重要方向。现有研究多聚焦于单一城市或单一房源类型（二手房或租房），缺乏跨城市、跨市场的系统性比较分析，对城市间住房定价逻辑差异的量化研究尚不充分。

与此同时，中国城市住房市场呈现出显著的分化特征。一线及新一线城市房价高企、市场活跃，而三四线城市则面临库存压力、价格增长乏力。这种分化不仅体现在价格水平上，更可能反映在价格形成的微观机制中——不同能级城市的购房者可能对不同特征的支付意愿存在系统性差异。然而，现有研究较少从“价格形成机制”的角度对多城市进行平行比较，对城市内部空间分化的量化分析也有待深化。

本研究以安居客平台杭州、金华、临沂三城市的二手房与租房数据为研究对象，围绕“城市住房市场价格形成与分化”这一核心问题展开系统分析。三座城市分别代表高能级（杭州）、中等能级（金华）和低能级（临沂）的市场类型，为跨城市比较提供了天然的分层样本。研究旨在揭示不同能级城市在住房定价逻辑上的系统性差异，为理解中国城市住房市场的多层次结构提供实证参考。

数据采集覆盖三城市的二手房与租房两大主力品类，经清洗后共获得有效房源样本数万条，包含房源基础信息（面积、总价、户型、楼层、朝向、装修、建成年份、电梯配置、物业类型等）和小区配套信息（行政区、周边设施、在售/在租数量等），能够满足多维度分析的需要。

1.2 研究问题

本研究以“不同能级城市住房市场的价格形成机制与供给结构分化”为核心主线，提出一个整体研究问题和四个子问题，分别对应探索性分析、回归分析、聚类分析和预测分析模块。

整体研究问题：不同能级城市的住房定价逻辑是否存在系统性差异？这种差异是否伴随着租售比的显著错配？这些差异与错配现象主要体现在哪些微观特征维度？其背后的市场分化机制如何？

子问题一（探索性分析）：不同能级城市（如杭州、临沂等）的二手房与租房市场在价格分布、面积结构、房龄、装修程度、配套设施以及租售比（在租房源数量与在售房源数量之比）等方面呈现出何种特征差异？这些差异是否已显示出明显的市场分化信号？本部分通过多维度描述性统计、分布可视化、相关性分析和组间对比，为后续建模提供经验依据和研究方向。

子问题二（回归分析）：面积、楼层、装修、电梯、物业类型、房龄、区位等特征对

房价和租金的边际贡献如何？这些特征的影响效应在不同能级城市间是否存在显著异质性？（例如高能级城市的精装修溢价是否更高？）

子问题三（聚类分析）：各城市的房源能否根据价格、房龄、配套等特征划分为若干具有显著差异的群体？不同城市、不同房源类型（二手房 vs 租房）的市场结构是否存在系统性差异？

子问题四（预测分析）：基于房源及小区特征能否构建有效的房价/租金预测模型？哪些特征是最关键的预测变量？不同模型（随机森林 vs XGBoost）在不同能级城市的表现是否存在差异？

四个子问题构成“数据认知 → 机制解释 → 模式发现 → 预测验证”的完整逻辑链条。本研究创新性地聚焦**租售比错配**这一现实问题，结合城市能级对比和多方法验证，尝试揭示中国城市住房市场的结构性分化特征。

2 数据爬取与清洗

2.1 数据爬取思路

本研究的数据采集目标为安居客平台杭州、金华、临沂三城市的二手房与租房房源信息。三座城市分别代表高能级（杭州）、中等能级（金华）和低能级（临沂）的市场层级。数据采集分为四个层次逐级展开：

第一层：小区列表爬取。为了保证爬取的小区与房源信息的完整，我以安居客小区频道为入口，按照热度高到低的排序遍历各城市的小区列表页从每个小区卡片中提取小区详情页链接（链接列表页的 URL 模式为 `https://{city}.anjuke.com/community/p{page}/`，小区详情页 `community/view/{id}/`）和标签信息（如“近地铁”“近学校”“配套齐全”等）。该层共爬取杭州、金华、临沂三城市小区链接各 1,250 条（我们爬取了每个城市的安居客的小区页面各 25 页，每页各有 50 个小区）。

需要说明的是，该抽样策略按照平台热度排序进行采集，而非完全随机抽样。安居客的热度排序综合反映了小区的规模、挂牌房源数量、交易活跃度和用户关注度，因此热度较高的小区构成了住房市场中实际交易和挂牌的主要部分。从覆盖率来看，每城市 25 页 × 50 个小区的采集量已覆盖平台展示的小区主体——在平台默认的展示逻辑下，热度排序靠后的小区通常房源稀少、交易冷清，对城市整体市场特征的贡献有限。因此，本研究的样本能够有效反映各城市住房市场的主流价格水平和供给结构，研究结论主要适用于市场中活跃的交易部分。对于偏远区域或交易极不活跃的小区，本研究结论的推广需保持审慎。

第二层：小区详情爬取。在得到小区链接后，逐一访问小区详情页，提取各小区的字段信息，包括小区名称、地址、挂牌均价、竣工时间、在售/在租房源数量，以及物业类型、建筑类型、容积率、绿化率、物业费等配套字段。同时，通过点击页面中的“公交”“地铁”“学校”“餐饮”“购物”“医院”“银行”七个选项卡，提取周边配套设施的

数量和名称。该层完整覆盖第一层获取的所有小区。

第三层：房源链接提取。基于小区详情页中的“二手房（N 套）”和“租房（N 套）”链接，进入各小区的房源列表页，提取该小区对应的在售/在租房源的详情页链接。对于每个小区的每种房源类型，仅爬取第一页，以保证数据覆盖广度与爬取效率的平衡。

第四层：房源详情爬取。逐一访问房源详情页，提取房源基础信息：房源 ID、标题、行政区、小区名称、户型、面积、总价/月租金、楼层、朝向、装修程度、建成年份、电梯配置、物业类型及标签描述。爬取到的各城市二手房与租房的房源信息条数如表 1 所示：

表 1: 各城市爬取到的房源信息条数（清洗前）

城市	二手房	租房	合计
杭州	11,090	10,484	21,574
金华	8,454	4,988	13,442
临沂	9,828	7,735	17,563
合计	29,372	23,207	52,579

在技术实现上，爬虫采用 Selenium WebDriver 驱动 Edge 浏览器，通过 CDP 命令隐藏自动化特征以降低被反爬识别的概率。针对安居客的验证码和“安全验证”页面，设计了显式等待与手动干预结合的处理机制：检测到验证码时暂停爬取并提示用户手动完成，完成后按回车键继续。每个请求之间设置 3–10 秒的随机延时，每处理 50 个小区主动暂停 2 分钟，以模拟人类浏览行为。针对小区详情页中周边设施选项卡的动态加载，采用 JavaScript 点击和显式等待策略，确保数据完全渲染后再提取。

爬取完成后的原始数据按房源与小区两个维度组织。

在开始数据清洗之前，有必要对本研究采集样本的可靠性与代表性进行说明。

抽样策略的合理性。本研究的采样策略按照平台热度排序进行采集，而非完全随机抽样。安居客的热度排序综合反映了小区的规模、挂牌房源数量、交易活跃度和用户关注度，因此热度较高的小区构成了住房市场中实际交易和挂牌的主要部分。从覆盖率来看，每城市 25 页 × 50 个小区的采集量已覆盖平台展示的小区主体——在平台默认的展示逻辑下，热度排序靠后的小区通常房源稀少、交易冷清，对城市整体市场特征的贡献有限。因此，本研究的样本能够有效反映各城市住房市场的主流价格水平和供给结构。

样本的城市代表性。三座城市分别代表高能级（杭州）、中等能级（金华）和低能级（临沂）的市场类型。从平台展示的小区总量来看，杭州约 1800 个活跃小区、金华约 1500 个、临沂约 1400 个，本研究实际采集各 1250 个小区，覆盖率分别为 69%、83% 和 89%。该覆盖率在低能级城市中更高，因为其小区总量相对较少且集中度更高，而高能级城市中更多边缘小区未被纳入样本。考虑到未纳入的样本多属于交易极不活跃的边缘小区，本研究样本对城市住房市场的主体结构具有充分的代表性。

可能存在的选择偏差。需要指出的是，热度排序本身可能引入一定的选择偏差——热度较高的小区通常在区位、配套、房源品质等方面优于城市平均水平，这可能导致样

本中高价位、高品质房源占比略高于市场真实结构。同时，安居客平台本身并非所有房源发布的唯一渠道，部分房源可能仅通过线下中介或其他平台挂牌，因此本研究的样本主要反映的是线上挂牌市场，而非全量住房市场。上述偏差在一定程度上会影响描述性统计中绝对数值的精确性（如城市均价的具体水平），但不会显著影响本研究关注的核心问题——各特征对价格的边际效应及其跨城市差异——因为效应量的估计对样本均值的偏移相对稳健。

研究结论的适用范围。基于上述分析，本研究的结论主要适用于各城市住房市场中活跃交易的线上挂牌部分。对于偏远区域、交易极不活跃的小区或完全依赖线下渠道的房源，本研究结论的推广需保持审慎。研究所揭示的城市间定价逻辑差异和空间分化格局，在活跃市场部分具有较高的可信度，但对于边缘市场的适用性尚待进一步验证。

2.2 数据清洗与填充思路

原始数据采集完成后，面临三个主要问题：字段缺失、字段值不规范以及房源与小区信息的分离。清洗与填充流程按以下步骤进行。本节不仅说明每一步做了什么，也解释为什么选择当前方案而非其他替代方案——这些设计决策直接影响最终数据集的质量和研究结论的可信度。

前置处理：行政区补爬。在初步爬取中发现部分房源数据中的行政区字段存在错误（如将“观巷小区租房”等非行政区文本写入）。这可能是由于安居客对应网页时间跨度大、信息存储结构不完全一致所致。由于重新爬取所有房源耗时过长，我们编写修复脚本 `district_fix.py`，从小区详情页的标题区域重新提取行政区（例如“上城-南星-钱江路 158 号”，提取第一个“-”之前的部分），更新至小区链接表中。后续清洗阶段通过 `community_id` 字段关联该表，完成行政区字段的修正与填充。行政区是后续分区统计和区位分析的核心变量，如果直接使用错误数据将导致所有分区分析结论失效；选择补爬小区详情页而非重新爬取所有房源，是因为前者数据量更小（小区总数远少于房源总数），且小区详情页的标题格式相对规范，提取准确率更高。

第一步：去重与文本清洗。按 `house_id` 对房源数据进行去重，保留非空字段最多的记录（即信息最全者），而非强制要求全部字段完整。对所有字符串字段执行换行符清洗（将 `\n` 和 `\r` 替换为空格），确保 CSV 在不同工具中行数一致，避免 Excel 解析错误。去重时选择“保留非空字段最多”而非“随机保留一条”或“保留最新一条”，是因为不同爬取轮次获取的字段完整度不同——部分房源的某些字段可能因页面加载失败而缺失，在下一轮爬取中反而可能获取到，保留信息最全的记录可以最大化数据利用率。去重键选择 `house_id` 而非 URL，是因为 `house_id` 是平台内部房源唯一标识，格式稳定，不易受 URL 参数变化影响。

第二步：缺失值填充。采用三源融合策略：（1）建成年份（`build_year`）优先使用小区信息表中的竣工年份，若缺失则保留房源自身字段；（2）行政区（`district`）完全由补爬后的小区链接表通过 `community_id` 覆盖；（3）电梯字段（`elevator`）分两轮填充：第一轮从房源的标题、标签（`tags`）和页面标签（`page_tags`）中提取关键词（“电

梯房”“有电梯”等判定为有电梯，“无电梯”“步梯房”等判定为无电梯，同时出现矛盾表述则放弃推断）；第二轮基于小区一致性填充电梯——若同一小区内所有非空电梯值一致，则将该小区所有空值填充为该值，否则保持空值。该策略同时利用二手房和租房数据，跨类型联合判断，最大化填充覆盖率。建成年份优先使用小区表信息，是因为小区竣工时间是一个确定性属性，不应因房源类型不同而不同——同一小区的二手房和租房理应共享相同的建成年份。行政区完全由小区表覆盖，是因为房源表中的行政区字段存在前述错误，而小区详情页的行政区信息相对准确。电梯字段采用两轮填充而非直接删除缺失样本，是因为电梯配置在住房市场中是一个高区分度特征（无电梯房源通常价格更低），直接删除会导致样本选择偏误；第一轮从文本中提取关键词利用了房源标题和标签中丰富的描述信息，第二轮基于小区一致性利用了“同一小区建筑标准通常一致”的业务逻辑。同时利用二手房和租房数据进行联合判断，是因为同一小区的电梯配置不会因挂牌类型不同而改变，跨类型联合可以增加一致性判断的样本量。

第三步：物业类型字段标准化。房源表中物业类型（property_type）比较混乱，这是因为安居客网站本身对物业类型这一字段填写得非常随意，为了让房源表中的物业类型尽可能地统一，我们分析了房源表中的物业类型，主要有“普通住宅”、“公寓”、“别墅”、“排屋”、“平房”与“其他”六类，因此我们先将房源表的物业类型统一映射成以上六类。而小区表中物业类型（property_type）相对有序，只有“住宅”、“别墅”与“商住楼”三种。我们发现安居客对于物业类型的分类非常混乱，从房源处获取到的物业类型字段与从小区获取到的物业类型并无法对应，而且从房源维度获取到的物业类型会出现同一个小区的房源物业类型可能不一样，这与现实逻辑似乎并不符合。因此，我们以小区维度获取到的物业类型作为房源的物业类型，实现该字段的统一。选择以小区表为准而非房源表，是因为物业类型本质上是小区级别的属性——一个小区不可能同时是“普通住宅”和“别墅”，房源表中同小区出现不同物业类型只能说明房源页面的字段填写错误，以小区表覆盖房源表是纠正这一逻辑错误的最直接方式。

第四步：产权类型与产权年限清洗。产权类型（ownership_type）在原始数据中存在大量混杂表述，包含“商品房住宅”、“动迁配套房”、“经济适用房”、“公租房和廉租房”、“办公”、“商业”、“单位集体自建房”、“小产权房”等多种类型，且存在大量“|”分隔的组合类型（如“商品房住宅 | 公租房和廉租房”），直接使用会导致类别过于细碎、无法有效建模。本研究将产权类型归并为五个大类：纯商品住宅、保障/政策类住宅（含动迁配套房、经济适用房、单位集体自建房）、商办类（含办公、商业）、公共租赁房（含公租房和廉租房）、高风险/无产权（含小产权房、集体租赁住房 and 城中村）。对于产权年限（property_years）字段，原始数据以“70 年”、“50 年”等文本形式存储，本研究从中提取数值部分（40、50 或 70 年），缺失值则按该小区所属产权类型的众数进行填充——因产权年限本质上仅有 40、50、70 三种法定年限，采用众数填充比中位数更符合实际业务逻辑。例如，纯商品住宅的缺失值填充为 70 年，商办类填充为 40 或 50 年，保障房类填充为 50 年。清洗后，产权类型成为有序的分类变量，产权年限成为可参与回归与预测的连续型特征，二者共同纳入后续建模的特征集。产权类型的归并逻辑

辑基于两类判断——法律性质（土地用途）和交易风险（能否自由流通），五个大类的划分既保留了关键的业务区分度（商品住宅 vs 保障房 vs 商办），又避免了类别过细导致的建模困难。产权年限采用众数填充而非均值或中位数，是因为产权年限本质上是离散的法定年限（40、50、70 年），商业用地不可能填充为 70 年，均值填充会产生非法的“中间值”；按产权类型分组填充众数，利用了“同类产权对应同一年限”的业务规律。

第五步：楼层数据清洗提取。房源表中 floor 字段的原始格式参差不齐，除“中层（共 11 层）”、“共 3 层”等规范表述外，亦混有“东园高层公寓（拱墅宝善）”等既无楼层类型亦无总层数信息的错误值。为得到结构化的楼层特征，我们按以下逻辑进行解析：优先匹配“类型（共 X 层）”格式，提取括号前的部分作为楼层类型（floor_type），括号内的“共 X 层”作为总层数（total_floor）；若不匹配括号格式，则检索“共 X 层”关键词，将其提取为总层数，剩余部分作为类型；若两者均无，则将整个字符串视为楼层类型。同时，为过滤错误数据，我们定义了有效楼层类型的白名单（包含低层、中层、高层、地下、底层、顶层、平层），解析后若提取出的楼层类型不在白名单内，则将其置为空字符串，但保留可能获得的 total_floor。对于完全无法提取出有效类型且无总层数信息的记录，两字段均置为空，并将原 floor 字段也清空，以确保数据一致性。最终在房源表中新增 floor_type 和 total_floor 两列，对原字段缺失或解析失败的记录统一填充为空字符串，以便在后续步骤中通过过滤剔除无效记录。价格单位（二手房总价单位为万元，租房月租金单位为元/月）在原始数据中已保持统一，本步骤仅作说明，不进行额外代码处理。楼层信息的解析难度在于原始数据的不规范性，我们选择“提取结构化信息、过滤无效记录”的策略而非“保留所有原始值”，是因为楼层类型和总层数在回归分析和聚类分析中都具有明确的解释意义——楼层类型反映垂直区位（采光、噪音），总层数反映建筑高度（社区密度、电梯依赖性）；定义有效楼层类型白名单是为了过滤掉完全无法归类的错误值，避免在后续分析中引入噪声。

第六步：朝向清洗。房源表中的朝向（orientation）字段原始表述多样，例如“南”、“朝南”、“南北”等，且存在“东、南”等多方向组合。为保证后续分析的一致性，我们对朝向字段进行规范化处理：若字符串中仅包含单一方向关键字（“东”、“南”、“西”、“北”之一），则直接输出该方向；若同时包含多个方向关键字或方向信息不明确，则保留原字符串不做修改。清洗后，单一方向房源统一为“东”、“南”、“西”、“北”四类，便于后续分类统计与建模。选择只对单一方向进行清洗、保留多方向原始值，是因为多方向组合（如“南北”通透）本身包含两个方向信息，直接拆分为单一方向会损失“通透性”这一重要信息；而简单归并为一个新类别（如“南北通透”）则需要额外的业务知识来判断归并标准，可能引入主观偏差，保留多方向的原始值可以让后续建模者根据实际需求决定如何处理。

第七步：完整数据提取。基于作业要求的房源基础信息表和小区配套标签表字段，从清洗后的数据中筛选所有关键字段均非空的记录，生成“完整房源数据.csv”和“完整小区数据.csv”，作为后续分析的输入数据集。其中，房源数据额外要求 floor_type 和 total_floor 不同时为空，确保每条房源记录均包含有效的楼层信息。小区数据则

要求 community_name、tag、location、price、build_year、nsh、nrp 全部非空，以保证小区配套信息的完整性。步骤 7 采用了“先过滤有效小区，再以此过滤房源”的策略，而非对房源和小区分别独立过滤，这一设计的核心考量是数据一致性——如果某个小区因关键字段缺失被排除，那么引用该小区的所有房源也应被同步排除，否则会产生“孤儿房源”，导致后续分析中出现无法关联小区的样本。房源数据要求 floor_type 和 total_floor 不同时为空，是因为楼层信息在房价形成中具有理论上的重要性（高层低层存在价格差异），如果两者全无则该房源在楼层维度上完全不可用，排除是合理的。小区数据要求 nsh 和 nrp 非空，是因为这两个字段用于计算租售比（nrp/nsh），是本研究核心变量之一，必须保证其完整性。

最终清洗结果：三城市房源数据去重后保留有效记录共 44077 条，所要求的关键字段全部完整。清洗后各城市保留的有效房源与小区数量如表 2 所示。

表 2: 清洗后各城市房源与小区数量统计

城市	二手房	租房	小区	房源合计
杭州	9313	9247	1246	18560
金华	6069	3895	1170	9964
临沂	8198	6471	1221	14669
合计	23580	19613	3621	43193

清洗后的字段表结构如下。
房源数据包含以下字段（表 3）：

表 3: 房源数据字段说明

字段名	类型	含义
city	文本	所属城市（杭州/金华/临沂）
house_type	文本	房源类型（二手房/租房）
community_name	文本	小区名称
community_id	文本	小区唯一 ID（外键，关联小区表）
tags	文本	房源的标签描述
house_id	文本	房源唯一标识 ID（主键）
house_title	文本	房源标题
district	文本	行政区
layout	文本	户型格局
area	数值	建筑面积（m ² ）
total_price	数值	房屋总价（万元）或月租金（元/月）
floor	文本	所在楼层 / 总楼层

表 3: 房源数据字段说明

字段名	类型	含义
orientation	文本	房屋朝向
decoration	文本	装修程度（精装/简装/豪装/毛坯）
build_year	数值	建筑建成年份
elevator	文本	是否配备电梯（有电梯/无电梯）
property_type	文本	物业类型
page_tags	文本	房源具体描述
floor_type	文本	楼层类型
total_floor	数值	总层数

小区数据包含以下字段（表 4）:

表 4: 小区数据字段说明

字段名	类型	含义
community_id	文本	小区唯一 ID（主键）
community_url	文本	小区详情页链接
community_name	文本	小区名称
location	文本	小区详细地址
price	数值	小区当前挂牌均价（元/m ² ）
build_year	数值	竣工时间
nsh	数值	小区在售二手房数量
nrp	数值	小区在租租房数量
property_type	文本	物业类型
ownership_type	文本	权属类别
property_years	文本	产权年限
total_households	文本	总户数
total_area	文本	总建筑面积
plot_ratio	文本	容积率
greening_rate	文本	绿化率
building_type	文本	建筑类型
business_circle	文本	所属商圈
heating	文本	统一供暖情况
supply_type	文本	供水供电类型

表 4: 小区数据字段说明

字段名	类型	含义
parking	文本	停车位信息
property_fee	文本	物业费
parking_fee	文本	停车费
parking_management_fee	文本	车位管理费
property_company	文本	物业公司
developer	文本	开发商
around_ 公交	文本	附近的公交站（名称与距离）
around_ 公交 _count	数值	附近的公交站数量
around_ 地铁	文本	附近的地铁站
around_ 地铁 _count	数值	附近的地铁站数量
around_ 学校	文本	附近的学校
around_ 学校 _count	数值	附近的学校数量
around_ 餐饮	文本	附近的餐饮
around_ 餐饮 _count	数值	附近的餐饮数量
around_ 购物	文本	附近的购物场所
around_ 购物 _count	数值	附近的购物场所数量
around_ 医院	文本	附近的医院
around_ 医院 _count	数值	附近的医院数量
around_ 银行	文本	附近的银行
around_ 银行 _count	数值	附近的银行数量
tags	文本	小区的标签
city	文本	所属城市
tag	文本	小区具体描述

2.3 工作流程与技术路线

在进入特征工程与建模分析之前，本节对本研究的整体技术路线与代码实现架构进行说明，以帮助读者建立对后续章节分析逻辑的整体认知。

本研究的代码实现按“爬取 → 清洗 → 特征工程 → 分析建模”四个阶段组织，各阶段均独立封装为可复用的 Python 脚本，分别存放于对应目录下。各阶段的主要功能与模块划分如下：

第一阶段：数据采集。爬虫脚本以 Selenium 驱动 Edge 浏览器，遍历安居客平台杭州、金华、临沂三城市的小区列表页，逐级爬取小区链接、小区详情、房源链接与房源详情，最终输出各城市二手房与租房的原始数据文件。

第二阶段：数据清洗。按顺序执行去重与文本清洗、缺失值填充、物业类型标准化、产权类型与年限清洗、楼层数据提取、朝向清洗，以及完整数据提取等步骤，生成“完整房源数据.csv”和“完整小区数据.csv”作为后续分析的基础数据集。各清洗步骤独立封装为可重复执行的脚本，便于数据更新时重新运行。

第三阶段：特征工程。将房源表与小区表通过 `community_id` 关联，派生房龄、单价、租售比和配套得分等新特征，按“城市 × 房源类型”组合输出三类数据表(`complete.csv`、`house.csv`、`community.csv`)，供后续探索性分析与建模使用。该阶段的设计理念是为不同分析任务提供统一的基础数据，避免重复的数据处理工作。

第四阶段：分析与建模。分为四个相互独立但逻辑递进的模块——探索性分析（描述性统计与可视化）、聚类分析（K-Prototypes 算法）、回归分析（多元线性回归 + HC3 稳健标准误）和预测分析（随机森林 + XGBoost）。各模块均从前一阶段输出的基础数据表读取数据，独立运行，互不干扰，保证了代码的可维护性与结果的可复现性。

整个技术路线的设计遵循“分离关注点”原则：数据采集与清洗专注于数据质量和完整性，特征工程专注于变量构造与数据规范化，分析与建模专注于方法应用与结果解读。各阶段之间的接口通过标准化的 CSV 文件实现，确保了代码模块的可复用性与分析流程的透明性

3 特征工程

完成数据清洗后，原始数据已具备基本可用性，但距离直接输入模型仍有差距：一是房源表与小区表仍为分离状态，房源级别的区位配套信息需要通过关联才能获取；二是部分字段无法直接用于建模，需要派生处理；三是不同分析任务对数据格式的要求不同。因此，我们在清洗与建模之间增设了独立的特征工程环节，核心目标是将原始字段转化为结构化的基础数据表，为后续探索性分析与建模提供统一的数据输入。

特征工程按“城市 × 房源类型”组合独立执行，针对每一对组合（如“杭州二手房”）依次完成以下操作。之所以按组合独立处理，是因为不同城市、不同房源类型的市场特征和分布形态可能存在显著差异——杭州二手房与临沂二手房的价格量级不同，金华租房与杭州租房的面积分布也不同。若全局统一处理，中位数填充等操作会被跨城市的差异所扭曲。分组合处理能够保留各子市场的特异性，使填充值和截尾阈值更贴合该组合的实际分布。

首先将房源表与小区表通过 `community_id` 进行左连接，使每条房源记录附带小区的配套信息（周边公交、地铁、学校、餐饮、购物、医院、银行的数量）和品质指标（绿化率、容积率、挂牌均价等）。连接后每一条房源记录将附带其所在小区的完整配套与品质信息，为后续分析提供了房源级别与小区级别的双重信息。

在此基础上派生若干新特征。首先是房龄 (`house_age`)，以 2026 年为基准减去建成年份计算得出。之所以使用房龄而非建成年份进入模型，是因为购房者和租客感知的是房屋的“已使用年限”而非“哪一年建成”，房龄是更直接的折旧指标。其次是单价

(unit_price), 由总价除以面积得到, 用于二手房模型中以消除面积对总价的规模效应。第三是租售比 (rent_sale_ratio), 定义为小区在租租房数量与在售二手房数量之比 (nrp / nsh), 用以表征小区层面租赁与销售两类房源供给的结构关系, 是衡量不同城市住房持有用途分化的核心变量。此外, 来源于小区表的 greening_rate 和 plot_ratio 字段在原始数据中可能带有 “%” 符号, 需先去除后再转为数值类型。

在配套特征的处理上, 本研究分别计算了地铁、学校、医院、购物、餐饮五个维度的单项得分 (score_metro、score_school、score_hospital、score_shopping、score_dining), 并将其求和得到总配套得分 (total_amenity_score), 用于衡量小区周边的整体生活便利度。各配套维度的权重根据其出行依赖度和生活必需性设定: 地铁与学校权重最高 (3.0 和 2.5), 医院次之 (2.0), 购物 (1.6) 与餐饮 (1.3) 权重较低。配套得分采用对数变换 (log1p) 以缓解长尾分布的影响——部分小区周边配套数量极多 (如市中心小区可能有数十家餐饮), 直接使用原始计数会使得少数极端值主导得分, 而对数变换能够压缩长尾, 使得分反映 “配套丰富度” 而非 “配套绝对数量”。选择使用加权得分而非原始计数, 是因为不同配套对居住品质的边际贡献不同: 地铁决定通勤便利性, 学校关联子女教育, 医院关乎紧急医疗需求, 商业配套的边际贡献相对较低。权重设计反映了这一优先级差异。

缺失值处理方面, 周边配套计数类字段 (如 around_ 地铁 _count) 缺失时表示该小区附近无对应配套, 直接填充为 0——这是因为配套计数为 0 与缺失在业务含义上等价, 均表示该小区周边不存在该类设施。连续型字段 (如房龄、绿化率、容积率、小区挂牌均价等) 则采用该组合内的中位数填充。选择中位数而非均值, 是因为中位数对极端值不敏感, 在住房数据这类存在大量长尾分布的字段中更为稳健; 选择分组合独立计算中位数而非全局统一值, 则是因为不同城市、不同房源类型的分布中枢不同 (杭州的房龄中位数显著高于临沂)。面积和总价两个核心字段存在少量极端异常值 (如面积超过 1000 平方米的豪宅或总价异常偏高的挂牌房源), 采用三倍标准差准则进行截断处理, 将超出上下界的样本拉回边界。之所以选择 3 而非更严格的 2 或更宽松的 5, 是因为住房市场天然存在合理的价格和面积差异 (别墅与刚需房差异巨大), 2 会误删大量正常的高端房源, 而 5 则几乎起不到截尾作用; 3 在住房数据的异常值处理中是较为通用的折中选择。类别字段 (行政区、朝向、楼层类型、装修程度、物业类型、产权类型、电梯配置) 的缺失值统一填充为 “未知”——这一处理保留了这些样本的可用性, 同时通过 “未知” 类别将其与有效类别区分开来, 避免错误归入某一具体类别。所有分类变量在特征工程阶段均保留原始文本值, 不进行编码, 因为不同的下游任务可能需要不同的编码方式 (K-Prototypes 需要原始类别值, 线性回归需要 One-Hot 编码), 将编码决策延迟到具体建模阶段可以提高基础数据表的复用性。

文本列的处理上, 本研究在特征工程阶段删除了 house_title (房源标题)、page_tags (房源页面标签)、community_url (小区链接)、tags (房源标签) 和 tag (小区标签) 五个字段。这些字段虽然包含丰富的信息 (如 “地铁口” “精装修” 等描述), 但均为非结构化的自由文本, 直接纳入建模需要额外的自然语言处理流程; 而在本研究的分析框架

中，房源的结构化特征（面积、总价、楼层、朝向等）已经包含了这些标签所指向的核心信息。删除这些字段并不会丢失关键的结构化信息，同时避免了文本特征引入的额外复杂性和不确定性。

上述所有操作均按“城市 × 房源类型”组合独立执行，最终每个组合输出三类文件：

1. `complete.csv`：完整合并表，包含房源与小区的全部字段及所有派生特征，供后续相关性分析和建模使用；
2. `house.csv`：房源独立表，仅保留房源级别字段和派生特征，供房源层面的分布统计与可视化使用；
3. `community.csv`：小区独立表，仅保留小区级别字段和派生特征（含租售比、各配套单项得分及总分），供小区层面的分布统计与可视化使用。

分类变量在特征工程阶段统一保留原始值，One-Hot 编码、数据分割、特征标准化等操作将在后续的聚类分析和回归建模脚本中按需实现，以确保特征工程输出的基础数据表在不同分析任务间保持最大兼容性。

4 探索性分析

在建立回归模型、聚类分析和预测模型之前，本章首先对数据进行系统的探索性分析，以建立对数据整体形态的直观认知，并为后续建模提供经验依据。探索性分析从小区级别和房源级别两个层次展开：小区级别分析聚焦于各城市小区的基本特征、物业类型和周边配套；房源级别分析聚焦于各城市各类型房源的数量分布、价格特征和分类变量分布。本章所有图表均基于清洗后的完整数据生成，图中标注的具体数值为实际计算结果。

4.1 小区级别数据画像

小区是住房市场的基本空间单元，其价格水平、房源供给结构和周边配套特征构成了住房定价的重要基础。了解小区层面的数据分布，有助于理解后续回归分析和聚类分析中小区层面解释变量的统计特性。本节基于清洗后的完整小区数据，从价格分布、供给结构、产权类型、产权年限、物业类型和周边配套六个维度展开初步分析。

4.1.1 小区挂牌均价分布

小区挂牌均价反映了各城市住房市场的整体价格水平。图1展示了三座城市当前小区挂牌均价的分布情况。




图 1: 各城市小区挂牌均价分布

从分布形态来看，三座城市小区均价均呈现右偏分布，价格主体集中在低价区间，高价小区数量稀少。杭州小区均价横轴区间最高，价格上限可达 140000 /m²，频数峰值集中在 10000-20000 /m²，10000-30000 /m² 为房源主力区间，市场价格离散度最大，高低价小区分化极强；金华小区均价上限约 70000 /m²，频数峰值集中在 10000-20000 /m²，整体价格中枢低于杭州；临沂小区均价上限仅 50000 /m²，频数峰值集中在 5000-10000 /m²，是三座城市里均价整体最低的城市。

三座城市房价梯度清晰：杭州房价显著高于金华，金华高于临沂，与城市能级匹配；同时城市内部价格离散程度逐级递减，杭州内部房价分化最剧烈，高能级城市不同区位、品质小区价差明显，临沂市场价格分层最弱。

4.1.2 小区在售与在租房源供给结构

小区的在售二手房数量（nsh）和在租房源数量（nrp）反映了该小区在住房市场中的活跃程度和供给结构。图2展示了各城市小区的平均在售和在租房源数量。




图 2: 各城市小区平均在售/在租房源数量

结合图中数值可见，仅有金华小区的平均在售房源数量高于在租房源，杭州与临沂均呈现在租房源更多的特征。杭州小区平均在售房源 26.4 套，平均在租房源 38.8 套；金华小区平均在售 16.5 套、在租 11.8 套；临沂小区平均在售 16.9 套、在租 21.0 套。

所选取的这部分样本所代表的市场中，整体市场活跃度杭州遥遥领先，单小区平均房源总量（在售 + 在租）远高于金华、临沂。售租比（平均在售/平均在租）：杭州 $26.4/38.8 \approx 0.68$ ，金华 $16.5/11.8 \approx 1.40$ ，临沂 $16.9/21.0 \approx 0.80$ 。金华售租比远高于另外两座城市，说明当地住房以二手出售流通为主，自住置换需求占比更高；杭州、临沂售租比偏低，租赁市场供给充沛，住房持有用于出租的投资属性更强。

4.1.3 产权类型分布

产权类型反映了住房的土地性质和交易限制，是影响房屋价值和流通性的重要制度性因素。本研究将原始数据中杂乱的产权表述归并为四大可视化统计大类：纯商品住宅、保障/政策类住宅（含动迁配套房、经济适用房、单位集体自建房）、商办类（含办公、商业）、高风险/无产权（含小产权房、集体租赁住房 and 城中村）；原始数据中少量公共租赁房样本体量极低，归入保障/政策类住宅统一统计。图3展示了三座城市各产权类型的小区数量分布。




图 3: 各城市产权类型分布对比

从分布来看，纯商品住宅是三座城市的绝对主导类型，杭州、金华、临沂纯商品住宅小区占比分别约 89.6%、95.3%、94.2%，各城市占比均超过 85%。保障/政策类住宅方面，杭州保障房小区数量显著高于金华和临沂，这可能与高能级城市较早开展大规模保障性住房建设有关。商办类物业在杭州数量最多，反映了杭州作为区域经济中心的商业活力。高风险/无产权类型仅临沂存在少量样本，杭州、金华无对应小区，三类城市该类型整体仅有零星分布，占比极低。

值得注意的是，纯商品住宅的绝对主导地位在各城市高度一致，说明当前住房市场仍以商品房为主要供给形式；保障性住房虽然绝对数量有限，但在高能级城市中已形成一定规模，体现了城市间住房保障政策力度的差异。

4.1.4 产权年限分布

产权年限（property_years）指房屋所占土地的使用权年限，根据用地性质不同，通常为 40 年（商办）、50 年（综合/工业）或 70 年（住宅）。产权年限直接影响房屋的剩余使用价值和转手价格，是购房者和投资者关注的核心指标之一。本研究从小区原始数据中提取产权年限数值，缺失值按该小区产权类型的众数填充。各城市产权年限分布如图4所示。




图 4: 各城市产权年限分布（数量与占比）

三座城市的产权年限结构呈现高度一致的特征：70 年产权的住宅用地在所有城市中均占据绝对主导，杭州、金华、临沂占比分别为 94.9%、97.6%、97.9%，均超过 85%，这与前述纯商品住宅在产权类型中的主导地位相互印证。50 年产权物业对应保障/政策类住房，各城市均有少量分布，其中杭州 60 个小区、临沂 25 个小区、金华仅 16 个小区，高能级城市的保障性住房存量更为丰富。40 年产权商办类物业呈现差异化特征：金华 40 年产权小区数量 12 个、占比 1.0%，两项指标均为三城最高；杭州仅有 3 个小区、占比 0.2%，临沂仅 1 个小区、占比 0.1%，低能级城市商办小户型、商业公寓类物业占比相对更高。

从产权结构看，三座城市均以 70 年产权为绝对主导，住房市场的产权属性高度集中。非 70 年产权物业（40 年 +50 年）合计数量杭州 63 个、金华 28 个、临沂 26 个，整体随城市能级递减，杭州拥有最多的非 70 年产权小区，体现了其更为多元化的用地结构和更丰富的物业类型供给。

综合产权类型与产权年限两项分析，杭州的住房市场在产权结构上最为多元化——纯商品住宅之外，保障房与 50 年综合用地物业供给均领先于其他两座城市，反映出高能级城市在满足多层次住房需求方面的结构性优势。临沂的产权结构则最为单一，纯商品住宅与 70 年产权住宅占比均为三城最高，住房市场的产品层次相对集中，多样化物业类型供给不足。

4.1.5 物业类型分布

物业类型是影响住房价格的重要结构性因素。图5展示了三座城市小区的物业类型分布对比。




图 5: 各城市物业类型分布对比

三座城市中普通住宅小区数量均占据绝对主导：杭州住宅小区约 1160 个，金华约 1030 个，临沂约 1140 个，三者住宅体量接近。商住宅楼规模整体偏小，杭州商住楼数量最多，其次为金华，临沂商住楼最少；别墅类物业金华数量大幅领先，远高于杭州、临沂，临沂别墅数量略多于杭州。

供给结构层面，杭州拥有充足刚需住宅与商住公寓，但高端别墅存量偏低；金华市场呈现鲜明改善属性，别墅类改善物业供给规模突出，是三城别墅供给最充沛的城市；反观临沂，住房市场产品梯度单薄，存量小区几乎全部为普通刚需住宅，商住、高端别墅类物业存量规模微弱，整体产品差异化程度为三座城市最低。

不同城市物业类型的多样性差异反映了城市住房市场的发展阶段：杭州作为高能级城市，刚需住宅、商住公寓供给充足，可覆盖刚需、投资类客群；金华依托充沛的别墅供给形成鲜明的改善型市场特征；而临沂住房市场供给仍以刚需普通住宅为绝对核心，改善、商住类产品供给不足。

4.1.6 周边配套设施覆盖率

周边配套设施是衡量小区居住便利性和区位价值的重要维度。本研究将各小区的周边设施（公交、地铁、学校、餐饮、购物、医院、银行）从计数数据转换为二值变量（是否有该设施），以初步分析各城市小区的配套设施覆盖情况。图6展示了三座城市在七类设施上的覆盖率对比。




图 6: 各城市周边配套设施覆盖率对比

公交配套方面，三座城市覆盖率全部接近 100%，城市间无明显差异，基础公共交通普及度极高；地铁配套则呈现极强的城市梯度差距，杭州地铁配套覆盖率接近 90%，金华仅 35% 左右，临沂尚未开通地铁、无地铁配套覆盖样本，覆盖率为 0，轨道交通资源的落差是三座城市配套层面最核心的分界线。学校、餐饮、购物、银行四类基础生活配套在杭州与金华覆盖率均接近 100%，两者几乎不存在差距，临沂该四类配套覆盖率仅小幅低于杭州、金华，整体仍维持 95% 以上的高位水平。医院配套整体覆盖率小幅跌破 100%，三座城市医院配套覆盖率集中在 96%–98% 区间，相互间差距微小；而地铁是七类配套中整体覆盖率最低的品类，该特征源于轨道交通建设门槛高、覆盖范围受城市基建规模约束，大型医院服务半径更广，无需每个小区近距离布局医疗资源，因此医疗配套城市间分化较弱。

综合来看，城市配套完善度呈现杭州略高于金华、临沂紧随其后的格局，临沂仅在轨道交通配套上存在明显短板，公交、商超、学校、银行等基础便民配套的城市间差异十分有限，轨道交通配套则存在断崖式分层，这一特征意味着在后续回归分析中，地铁配套变量或许是区分三城区位价值、解释跨城市房价差异的核心关键变量。

4.2 房源级别数据画像

房源是住房挂牌流通与租赁的微观观测单元，房源挂牌总价、租赁月租金、房屋建筑面积、行政区供给规模、房龄、户型朝向、装修程度、电梯配置、楼层类型、物业类型均会直接影响住房挂牌定价、居住空间与区域市场热度，是构建房价、租金回归模型的核心被解释变量与控制变量。本节基于全量在售二手房、在租房源样本，从房源价格分布、房源面积分布、分行政区房源供给数量、产权类型、产权年限、房源房龄分布、房源朝向结构对比、装修程度、电梯配置、楼层类型、物业类型十一个维度展开描述统计，直观对比杭州、金华、临沂二手挂牌与租赁市场的微观结构差异。

4.2.1 二手房与租房价格分布特征

总价、月租金分别为二手房交易、住房租赁的核心价格指标，箱线图可直观展示价格中位数、四分位区间与极端高价异常值，清晰反映三城市场价格中枢与离散分化程度。图7为三座城市二手房总价、租房月租金箱线对比图。




图 7: 各城市二手房总价、租房月租金分布箱线图

从二手房总价维度看，三城价格梯度与小区挂牌均价规律完全匹配，杭州二手房整体总价中枢显著高于金华、临沂。杭州二手房箱体位置、上下四分位数均为三城最高，同时存在大量高总价极端异常值，总价上限突破 7000 万元，反映城市内顶豪改善房源供给充足，市场总价分化程度极强；金华二手房总价中枢居中，高价异常值数量与极值规模均低于杭州；临沂二手房总价箱体整体最低，高总价异常值稀少，整体交易市场以低总价刚需房源为主。

租赁市场月租金呈现与二手房总价一致的层级差异：杭州租房月租金中位数、四分位区间全面领先，且存在少量超高租金的高端租赁房源，月租金极值超过 27 万元/月；金华、临沂租金中枢依次降低，二者高租金极端样本数量极少，租赁市场以平价刚需小户型为主。整体来看，无论是二手房交易总价还是租赁月租金，三城价格分层严格遵循杭州 > 金华 > 临沂的城市能级排序，高能级城市同时具备更高的基础价格中枢与更丰富的高端高价房源，市场价格离散程度逐级下降。

4.2.2 二手房与租房建筑面积分布特征

房屋建筑面积是决定总价、租金的基础物理属性，不同城市、不同房源类型的主流户型面积存在显著分化。8为三城二手房、租房建筑面积箱线对比图。




图 8: 各城市二手房、租房建筑面积分布箱线图

二手房维度，金华、临沂二手房箱体区间高度接近，二者房源面积中位数、四分位数略高于杭州；杭州二手房主流户型面积偏小，大面积改善型房源多表现为离散异常值，极值面积约 560 m^2 ；金华、临沂二手房大面积异常样本更多，极值面积突破 1400 m^2 ，说明两地大户型、别墅类二手房供给占比相对更高，与前文物业类型分布结论相互印证。

租赁房源面积分布则呈现完全相反规律：临沂租房面积箱体最高，金华次之，杭州租赁房源面积整体最小。杭州租赁市场以小户型公寓、刚需单间为主，主流面积集中在低位区间；金华、临沂租赁房源的中位面积更大，大户型整租产品供给更充沛，且三城均存在少量超大面积整租房源作为高值异常点。综合来看，二手房市场金华、临沂大户型供给更充足，租赁市场户型小型化程度随城市能级提升而加剧，杭州租赁小户型特征最为突出。

4.2.3 分行政区房源供给数量分布

各行政区二手房、租房房源数量直观反映区域房地产市场交易与租赁活跃度，能够识别城市内部核心热门片区与远郊、县域冷寂片区。图9、10、11分别为杭州、金华、临沂各行政区二手与租赁房源数量分组柱状图。




图 9: 杭州各行政区二手房、租房房源数量分布

杭州各区县房源供给呈现显著的主城集中特征，余杭区房源总量位居全市首位，二手房 1566 套、租房 1575 套，二手与租赁供给规模基本持平；上城区、临平区、滨江区、萧山区为第二梯队热门片区，二手、租房双维度均具备充沛供给；临安、富阳、桐庐、淳安等远郊、县域房源规模大幅收缩，其中淳安县、建德市租赁房源近乎枯竭，县域市场以二手房置换流通为主，租赁需求薄弱。整体而言，杭州主城及近郊新区二手、租赁市场同步活跃，远郊县域仅存在少量二手房流通，租赁市场发育不足。




图 10: 金华各行政区二手房、租房房源数量分布

金华房源供给高度集中于婺城区，该区二手房样本 2927 套、租房 1744 套，无论二手还是租赁房源规模均断层领先全市，且二手房供给量显著高于租赁，与金华整体售租比偏高、置换自住需求为主的市场特征匹配；东阳、金东、永康为次级活跃区域，二手、

租房均有一定存量；兰溪、武义、浦江、磐安等县域房源总量大幅缩减，磐安县无租赁样本供给，县域住房流通几乎仅依靠二手房交易，租赁市场近乎空白。




图 11: 临沂各行政区二手房、租房房源数量分布

临沂房源集中于兰山区，二手房 2214 套、租房 2074 套，二手与租赁供给规模均衡，是全市交易、租赁双核心；北城新区、罗庄区、河东区构成第二梯队热门片区，城区内部供需活跃度均衡；临沭、沂南、蒙阴、高新区等外围区县房源总量大幅走低，多数县域租赁房源存量显著少于二手房，外围片区租赁需求偏弱。对比三城行政区供给结构可见，杭州多片区均衡活跃，金华单核心高度集聚，临沂主城 + 近郊多片区协同发展，城市内部住房市场空间分化模式存在明显差异。

4.2.4 房源产权类型分布

产权类型反映了住房的土地性质与交易约束，是决定单套房源流通价值、交易门槛的核心制度变量。本研究整合原始房源数据中多元产权描述，归并为四大统计类别用于可视化分析：纯商品住宅、保障/政策类住宅（涵盖动迁配套房、经济适用房、单位集体自建房）、商办类（含商业商铺、办公公寓）、高风险/无产权（包含小产权房、集体租赁住房、城中村房源）；原始样本中少量公共租赁住房房源体量极低，统一归入保障/政策类住宅进行汇总统计。图12对比了三座城市不同产权类型的房源总量分布。




图 12: 各城市房源产权类型分布对比

从房源规模分布来看，纯商品住宅房源在三座城市中均占据绝对主体地位，杭州纯商品住宅房源总量最高，临沂次之，金华规模相对更低。商办类房源数量呈现杭州领先、金华与临沂依次递减的格局，印证杭州作为区域中心城市商业不动产供给更充沛。保障/政策类住宅房源同样以杭州存量最多，临沂、金华仅有少量房源，体现高能级城市保障性住房供给规模更大。高风险/无产权房源仅临沂存在极少量样本，杭州、金华几乎无对应房源，三类城市该类房源整体占比极低。

整体来看，商品房供给是三城二手房源市场的绝对主力，市场底层供给结构高度趋同；城市能级差异主要体现在商办物业与保障性房源的绝对供给规模上，杭州多层次房源供给的体量优势显著。

4.2.5 房源产权年限分布

产权年限 (property_years) 代表房源对应土地使用权期限，分为 40 年商办用地、50 年综合/工业用地、70 年住宅用地三类，直接影响房源剩余使用年限、贷款政策与市场估值。本研究提取单套房源产权年限字段，缺失样本按照同小区产权类型众数完成填充。各城市房源产权年限的数量、占比分布如图13所示。




图 13: 各城市房源产权年限分布（数量与占比）

三座城市房源产权年限结构呈现高度统一的特征：70 年住宅产权房源在全部城市中占绝对主导，杭州、金华、临沂占比分别为 93.6%、96.2%、97.3%，均超过 90%，与前述纯商品住宅房源的主体地位形成相互印证。50 年产权房源对应综合用地与保障性住房，杭州房源数量达 1123 套，显著高于临沂 377 套、金华 198 套，高能级城市保障性与综合类物业的房源供给更丰富。40 年商办产权房源则呈现差异化特征，金华 40 年房源 177 套、占比 1.8%，两项指标均为三城最高；杭州仅 56 套、占比 0.3%，临沂仅 18 套、占比 0.1%，中小城市商办公寓类房源相对占比更高。

从产权多元化程度来看，非 70 年产权房源（40 年 +50 年）合计规模杭州 1179 套、临沂 395 套、金华 375 套，整体绝对体量随城市能级递减，杭州拥有最丰富的非住宅属性房源，用地结构与物业供给更多元。临沂房源产权结构最为单一，70 年住宅房源占比三城最高，市场房源以普通商品住宅为绝对核心，多元物业供给稀缺。

综合房源产权类型与产权年限两项维度分析，杭州二手房源市场产权结构丰富度显著领先金华、临沂，除主流纯商品住宅外，保障类、商办类房源供给体量均具备明显优势，能够匹配多元化的居住、投资需求。临沂房源市场结构高度集中于 70 年商品住宅，物业类型层次单一，保障性与商业不动产房源供给不足；金华介于两者之间，商品房占比偏高，但商办类小户型房源相对占比突出。

4.2.6 房源房龄分布特征

房龄代表楼栋建成时长，直接关联建筑损耗、设施新旧与居住价值，是影响挂牌定价、租金水平的关键连续变量。图14为三座城市在售二手房、在租房源房龄分布箱线图。




图 14: 各城市二手房、租房房龄分布箱线图

在售二手房维度，杭州二手房房龄整体高于金华、临沂。杭州二手房房龄箱体中位数、四分位数更高，存在大量超过 40 年的老旧房源，极值房龄超过 60 年；金华、临沂二手房房龄中枢更低，主流挂牌二手房建成时间更新，极端老旧房源数量更少。

租赁房源房龄分布与二手房呈现差异化特征：金华租赁房源整体房龄最高，箱体区间、中位数均高于杭州与临沂，租赁市场大量流通建成周期较长的存量住宅；杭州租赁房源房龄居中，老旧租赁房源离散异常值较多；临沂租赁房源房龄整体最低，挂牌出租房源以建成时间较新的小区为主。

分城市对比可见，杭州城市开发起步最早，存量住宅新旧跨度极大，无论二手还是租赁市场均存在大量老旧房源；金华租赁市场更依赖早期建成住宅，二手房新建房源占比更高；临沂整体城市开发周期偏晚，在售、在租房源整体房龄更短，老旧住宅存量最少。

4.2.7 房源朝向结构对比

户型朝向直接决定住宅日照时长与室内通风效果，是影响挂牌总价、月租金的关键分类变量。图15展示三座城市在售、在租房源各朝向的占比构成。




图 15: 各城市房源朝向构成对比

南向、南北通透为三座城市挂牌房源的两大主流朝向，但城市间结构差异显著。杭州纯南向房源占比高达 84.9%，南北通透房源仅占 10.8%，市场以单一南向刚需户型为绝对主体；金华、临沂格局完全相反，南北通透户型占比分别达到 66.8%、63.7%，纯南向房源占比仅 28.7%、31.0%，改善型南北通透户型为市场主流。

东、西、东南、西南、东北、西北、东西等其余朝向房源在三城占比均不足 2%，属于小众户型，对整体市场结构影响微弱。其中杭州各类小众朝向房源合计占比略高于金华、临沂，户型朝向多元性更强；金华、临沂非南北系朝向房源存量极少，户型设计更偏向改善型南北通透标准。

该分布差异与城市户型规划逻辑高度相关：杭州大量小户型公寓、刚需高层仅设计单一南向采光，南北通透改善户型供给稀缺；金华、临沂新建住宅普遍采用南北通透板式楼栋设计，具备对流通风条件的改善户型占据市场主流，与前文别墅改善房源占比更高的市场特征形成互洽。

4.2.8 房源装修程度结构对比

装修程度是直接影响住房挂牌总价与租金水平的重要虚拟变量，不同城市存量住宅的装修改造习惯存在差异，使得在售、在租房源的装修档次分布形成明显分化。图16展示三座城市房源装修档次的占比构成。




图 16: 各城市房源装修程度构成对比

精装修房源在三座城市当前挂牌的在售、在租房源中均为绝对主流，但占比存在梯度差异：杭州精装修房源占比最高，达到 78.3%；临沂次之，精装修占比 73.2%；金华精装修占比仅 69.7%，为三城最低。简单装修房源占比排序与精装修完全相反，杭州简单装修占 16.8%，临沂 13.8%，金华仅 4.6%。

毛坯与豪华装修两类改善型房源呈现金华独高的特征：金华毛坯房源占比 13.2%、豪华装修占比 12.5%，两项指标均大幅超过杭州、临沂；杭州毛坯仅 3.0%、豪装 1.9%，临沂毛坯 11.0%、豪装 2.0%。

该分布特征与前文物业类型结论互洽：金华别墅改善类挂牌房源供给充足，大面积别墅多为毛坯交付或业主定制豪华装修，拉高两类装修房源占比；杭州存量挂牌房源以刚需精装公寓、精装商品房为主，毛坯、高端定制装修房源稀缺；临沂刚需普通住宅为挂牌主体，少量毛坯房源多为老旧小区，豪华改善装修房源存量极少。

4.2.9 房源电梯配置结构对比

电梯配置反映楼栋建筑年代与居住品质，无电梯老旧多层房源通常挂牌总价、租金更低，是区分存量房源品质的核心二元特征。图17为三城在售、在租房源电梯配置占比分布。




图 17: 各城市房源电梯配置构成对比

三座城市带电梯挂牌房源占比均突破 94%，当前存量挂牌房源以高层电梯住宅为绝对主流，城市间差异微弱。临沂有电梯房源占比最高，达 95.6%；金华次之，占 95.3%；杭州最低，为 94.2%。对应无电梯老旧多层房源占比呈现反向排序：杭州无电梯房源 5.8%，金华 4.7%，临沂仅 4.4%。

杭州无电梯房源占比更高，源于城市开发起步更早，核心老城区留存大量多层老式住宅，进入二手挂牌流通；临沂、金华城市集中开发周期相对滞后，存量老旧无电梯小区规模更小，电梯商品房在挂牌房源中占比更高。整体来看电梯配套在三城存量房源中均高度普及，该变量城市间区分度较弱，但会在城市内部形成房源品质分层。

4.2.10 房源楼层类型结构对比

高层、中层、低层、地下楼层直接关联采光、通行便利性与居住体验，不同城市楼栋规划高度差异带来存量挂牌房源的楼层分布区别。图18展示三城在售、在租房源楼层类型占比结构。




图 18: 各城市房源楼层类型构成对比

中层挂牌房源在金华、临沂占比显著更高，分别达到 38.1%、37.7%；杭州中层房源占比仅 34.5%。高层房源占比呈现杭州领先格局：杭州高层 34.8%，金华 33.1%，临沂 32.5%。低层房源占比逐级递减，杭州低层房源 30.6%，临沂 29.7%，金华 28.1%。地下楼层样本整体极为稀缺，仅金华存在少量地下房源占比 0.7%，杭州、临沂地下房源占比均仅 0.1%，对整体挂牌房源结构几乎无影响。

分布规律表明：杭州高层住宅挂牌供给相对更多，城市超高层、高密度住宅存量规模更大；金华、临沂主流楼栋以中层户型为主，社区容积率与建筑高度整体低于杭州。

4.2.11 房源物业类型结构对比

物业类型是划分刚需、改善、投资类挂牌房源的核心分类变量，前文小区层面仅统计小区数量，本小节从单套在售、在租房源维度对比各类物业挂牌存量占比。图19为三城房源物业类型百分比构成。




图 19: 各城市房源物业类型构成对比

普通商品住宅在三城所有挂牌房源中均占据绝对主体，临沂住宅房源占比 94.7%，挂牌供给结构最单一；杭州住宅占比 92.5%；金华住宅占比 90.0%，商品住宅占比最低，挂牌产品多元性最强。商住公寓挂牌房源供给杭州断层领先，占比 6.6%；金华商住 3.8%，临沂仅 2.6%，匹配杭州租赁、投资型商住公寓存量充沛的市场特征。别墅挂牌房源金华供给占比 6.2%，远高于杭州 0.9%、临沂 2.7%，再次验证金华改善型别墅产品挂牌存量充足的市场特征；自建房细分项样本占比不足 0.1%，不构成挂牌市场主流。

4.3 变量相关性与方差分析

在构建房价、租金回归模型前，本节一方面采用皮尔逊相关系数检验挂牌总价、建筑面积、房龄、租售比及各类配套得分等连续变量之间的线性关联强度，识别多重共线性隐患与变量内在关联逻辑；另一方面借助单因素方差分析（ANOVA）检验装修程度、电梯配置、楼层类型、物业类型、户型朝向、产权类型、产权年限七类分类变量对住房挂牌价格的解释作用，综合连续、分类两类变量的统计特征，为后续模型变量筛选与形式设定提供实证支撑。本节先基于三座城市合并的全量在售、在租房源样本开展整体分析，后续再分城市样本展开异质性对比讨论。

4.3.1 全样本连续变量相关性特征

图20与图21分别展示全样本二手房、租房核心连续变量的皮尔逊相关系数热力矩阵。




图 20: 全样本二手房变量相关性矩阵




图 21: 全样本租房变量相关性矩阵

针对二手房全样本的关联特征进行解读，挂牌总价与建筑面积的皮尔逊相关系数为 0.44，二者呈现中等强度正向线性关联，贴合住房市场基础定价逻辑，建筑面积更大的房源往往对应更高的挂牌总价，也反映出建筑面积是驱动二手房总价变动的核心正向基础变量。挂牌总价与房龄的相关系数为 0.11，呈现微弱正相关，说明在三城合并的全样本口径下，房龄与总价之间几乎不存在线性关联。建筑面积与房龄的相关系数为 -0.16 ，仅表现出微弱负相关关系，表明房龄更长的存量二手房整体户型建筑面积略偏小，但二者不存在具备实际统计意义的强线性绑定关系。

在配套特征方面，挂牌总价与地铁配套得分（score_metro）的相关系数达到 0.48，在所有配套维度中最高，凸显轨道交通对二手房价值的核心支撑作用；医院配套得分（0.12）与学校配套得分（0.03）的关联相对较弱，商业配套中的购物（ -0.06 ）与餐饮（ -0.11 ）得分甚至与总价呈现微弱负相关，反映商业设施在二手房定价中的边际贡献有限。总配套得分与挂牌总价的相关系数为 0.35，进一步验证了区位配套对房产价值的正向贡献。地铁配套得分与房龄呈现 0.40 的正相关，说明房龄较长的老城区在地铁可达性方面具有显著优势，这解释了房龄与总价微弱正相关的深层原因——老城区的成熟轨道交通网络抵消了房屋物理折旧。各配套单项得分之间，地铁与医院（0.35）、学校与医院（0.45）均呈现中等强度正相关，反映配套设施在空间分布上的协同集聚特征。购物得分与餐饮得分（0.33）的正相关则体现了商业配套的共生关系。

转向租房全样本的相关性规律，月租金与建筑面积的相关系数为 0.52，同样存在中等强度正向线性关联，且关联强度略高于二手房场景，说明在租赁市场中大面积房源同样能够获得显著的租金溢价。月租金与房龄的相关系数为 -0.07 ，呈现极微弱负相关，房龄变量对租赁价格的线性解释能力几乎可以忽略。建筑面积与房龄之间保持 -0.12 的弱负相关，与二手房样本中老旧房源户型面积偏小的规律一致。在配套特征方面，月租金与地铁配套得分的相关系数为 0.40，同样是最具解释力的配套维度，但其效应量低于二手房市场（0.48），表明租赁市场对交通便利性的支付溢价弱于买卖市场。总配套得

分与月租金的相关系数为 0.26，同样低于二手房场景，反映租户对整体区位配套支付意愿低于购房者，与租赁市场更关注通勤便利度的需求特征吻合。各配套维度中，学校（-0.04）、购物（-0.05）、餐饮（-0.11）得分与月租金均无正向关联，进一步印证租赁市场对商业及教育配套的敏感度显著低于买卖市场。

两类房源样本内，面积与房龄的负向关联均处于 0.12 ~ 0.16 的极微弱区间，租售比与其他变量之间的相关系数绝对值均低于 0.15，不会诱发严重多重共线性问题。这些发现为后续回归模型的特征筛选和变量设计提供了重要依据。

4.3.2 全样本分类变量单因素方差分析

为量化各类离散属性对住房价格的区分作用，以二手房挂牌总价、租房月租金分别作为因变量，对装修程度、电梯配置、楼层类型、物业类型、户型朝向、产权类型及产权年限七类分类变量开展单因素方差分析，全部样本的检验结果汇总于表5。

表 5: 全样本分类变量 ANOVA 检验结果

房源类型	分类变量	F 统计量	p 值	效应量 η^2	有效样本量
二手房	decoration（装修程度）	130.07	1.43×10^{-83}	0.0163	23580
二手房	elevator（电梯配置）	26.06	3.34×10^{-7}	0.0011	23580
二手房	floor_type（楼层类型）	331.52	4.46×10^{-278}	0.0533	23580
二手房	property_type（物业类型）	1753.48	0.0000	0.1295	23580
二手房	orientation（户型朝向）	240.03	0.0000	0.0840	23580
二手房	ownership_type（产权类型）	81.69	1.43×10^{-52}	0.0103	23580
二手房	property_years（产权年限）	99.78	7.05×10^{-44}	0.0084	23580
租房	decoration（装修程度）	108.89	6.36×10^{-70}	0.0164	19613
租房	elevator（电梯配置）	0.98	0.3224	0.0001	19613
租房	floor_type（楼层类型）	62.76	8.60×10^{-53}	0.0126	19613
租房	property_type（物业类型）	347.77	3.81×10^{-149}	0.0343	19613
租房	orientation（户型朝向）	18.72	1.80×10^{-31}	0.0085	19613
租房	ownership_type（产权类型）	27.50	9.78×10^{-18}	0.0042	19613
租房	property_years（产权年限）	5.25	0.0052	0.0005	19613

从二手房样本的检验结果来看，七类分类变量对应的 p 值均远小于 0.01，全部通过 1% 水平下的显著性检验，说明装修、电梯、楼层、物业、朝向、产权类型及产权年限均能够显著区分二手房挂牌总价的高低。对比各组效应量 η^2 ，物业类型的效应量达到 0.1295，在所有分类变量中断层领先，是解释二手房总价差异的最强因素；户型朝向（0.0840）和楼层类型（0.0533）同样具备较强的解释力；装修程度（0.0163）和产权类型（0.0103）具有中等偏弱的解释作用；产权年限（0.0084）的效应量进一步降低，但仍具统计显著性。电梯配置的效应量仅为 0.0011，虽因样本量较大而通过了显著性检验，但其实际区分能力极为有限。

切换至租房样本后，各类变量的显著性与解释力度出现明显分化。物业类型的效应量为 0.0343，虽仍为所有分类变量中最高，但已远低于二手房样本水平，表明建筑形态对租金差异的解释力度弱于买卖市场。装修程度（0.0164）和楼层类型（0.0126）次之，户型朝向（0.0085）与产权类型（0.0042）进一步降低，但仍通过 1% 显著性检验。电梯配置的 p 值为 0.3224，未通过显著性检验，意味着有无电梯对租赁房源租金不具备稳定的区分能力；产权年限的效应量仅为 0.0005，虽 p 值为 0.0052，但其实际解释力接近于零。整体而言，所有分类变量在租房样本中的效应量均低于二手房样本，反映离散属性对二手挂牌总价的解释作用整体强于租赁市场。

综上，物业类型是解释住房价格差异的最核心分类变量，楼层类型与朝向在二手房市场中解释力突出但在租房市场中明显减弱，电梯配置和产权年限的区分能力极其有限，为后续聚类特征筛选提供了统计依据。

4.3.3 分城市变量关联异质性分析

为挖掘杭州、金华、临沂三地市场在连续变量相关关系、分类变量价格解释力上的差异化特征，本节将分别提取各城市独立在售、在租房源样本重复开展相关性分析与单因素方差分析，对比不同城市房价形成机制的内在差异，为后续跨城市对比回归模型提供分样本统计依据。

4.3.4 杭州市场变量关联与价格解释力分析

针对杭州市场单独提取在售二手房、在租房源样本，重复开展连续变量相关性检验与分类变量单因素方差分析，挖掘杭州本地市场的房价形成机制特征，结果如下。

连续变量相关性特征 图22与图23分别展示杭州二手房、租房核心连续变量的皮尔逊相关系数热力矩阵。




图 22: 杭州二手房变量相关性矩阵




图 23: 杭州租房变量相关性矩阵

从杭州二手房样本的关联特征来看,挂牌总价与建筑面积的皮尔逊相关系数为 0.59,相较于全样本的 0.44 有明显提升,呈现中强度正向线性关联,说明在杭州市场中,建筑面积对二手房挂牌总价的解释力度显著高于全样本平均水平,是驱动本地二手房总价变动的核心主导变量。挂牌总价与房龄的相关系数仅为 0.00,二者完全不存在线性关联特征,房龄变量对杭州二手房总价不具备线性层面的解释能力。建筑面积与房龄的相关系数为 -0.03 ,同样几乎无线性相关,杭州市场中户型面积与房龄不存在具备统计意义的绑定关系。

在配套特征方面,杭州二手房挂牌总价与地铁配套得分的相关系数为 0.35,医院配套得分为 0.22,学校配套得分为 0.08,轨道交通对房价的支撑作用依然最为突出,但各配套维度的解释力度均低于全国水平。总配套得分与挂牌总价的相关系数为 0.27,同样低于全样本水平。值得注意的是,购物 (-0.12) 与餐饮 (-0.16) 得分与总价呈现负相关,这反映出杭州核心城区的商业设施可能并非稀缺资源,边际价值有限,与全国市场规律一致。地铁配套得分与房龄呈现 0.32 的正相关,医院配套得分与房龄亦为 0.32,说明杭州老城区在交通和医疗配套方面具有显著优势,这可以解释为什么房龄因素本身对总价几乎没有负面影响——老城区的区位配套溢价完全对冲了楼龄折旧。

转向杭州租房样本的相关性规律,月租金与建筑面积的相关系数达到 0.75,不仅远高于全国租房场景的 0.52,也超过了本地二手房市场中面积与总价的关联强度,呈现强正向线性关联,意味着在杭州租赁市场中,建筑面积是决定月租金水平的绝对核心因素,解释力度在所有变量中处于最高水平。月租金与房龄的相关系数为 -0.08 ,呈现微弱负相关,整体线性关联强度极弱。建筑面积与房龄之间保持 -0.12 的弱负相关,延续了全样本中老旧房源户型面积偏小的规律,但关联强度仍处于极低区间,不会诱发多重共线性问题。在配套特征方面,杭州租房市场呈现出与二手房市场一致但更弱的规律:月租金与地铁配套得分 (0.16)、医院配套得分 (0.05) 的相关性均明显低于二手房市场,总配套得分与月租金的相关系数仅为 0.08,购物 (-0.08) 与餐饮 (-0.16) 得分同样呈现负相关。这一系列结果表明,在杭州租赁市场中,租户对配套的支付意愿显著低于购房者,区位配套因素对租金的解释力度远不及面积因素。

分类变量单因素方差分析 以杭州二手房挂牌总价、租房月租金分别作为因变量,对装修程度、电梯配置、楼层类型、物业类型、户型朝向、产权类型、产权年限开展单因素方差分析,检验结果汇总于表6。

表 6: 杭州市场分类变量 ANOVA 检验结果

房源类型	分类变量	F 统计量	p 值	效应量 η^2	有效样本量
二手房	decoration (装修程度)	49.79	6.50×10^{-32}	0.0158	9313
二手房	elevator (电梯配置)	28.11	1.17×10^{-7}	0.0030	9313
二手房	floor_type (楼层类型)	45.74	2.48×10^{-29}	0.0145	9313
二手房	property_type (物业类型)	253.46	6.54×10^{-108}	0.0516	9313
二手房	orientation (户型朝向)	10.62	1.53×10^{-16}	0.0102	9313
二手房	ownership_type (产权类型)	194.77	1.36×10^{-83}	0.0402	9313
二手房	property_years (产权年限)	159.97	4.92×10^{-69}	0.0332	9313
租房	decoration (装修程度)	94.71	2.25×10^{-60}	0.0298	9247
租房	elevator (电梯配置)	8.46	0.0036	0.0009	9247
租房	floor_type (楼层类型)	26.59	5.88×10^{-22}	0.0114	9247
租房	property_type (物业类型)	153.92	1.75×10^{-66}	0.0322	9247
租房	orientation (户型朝向)	24.22	1.81×10^{-41}	0.0231	9247
租房	ownership_type (产权类型)	75.94	1.94×10^{-33}	0.0162	9247
租房	property_years (产权年限)	5.39	0.0046	0.0012	9247

从杭州二手房样本的检验结果来看，七类分类变量对应的 p 值均远小于 0.01，全部通过 1% 水平下的显著性检验，说明装修、电梯、楼层、物业、朝向、产权类型及产权年限均能够显著区分杭州二手房挂牌总价的高低。对比各组效应量 η^2 ，物业类型的效应量达到 0.0516，在所有分类变量中断层领先，是解释杭州二手房总价差异的最强因素；产权类型 (0.0402) 和产权年限 (0.0332) 同样具备较强的解释力，且远高于全样本水平，表明杭州市场对房屋的法律权属属性和剩余产权年限高度敏感，可能与杭州房地产市场中保障性住房、共有产权房等多元化产权形态并存有关；装修程度 (0.0158) 和楼层类型 (0.0145) 次之；户型朝向 (0.0102) 解释力度偏弱；电梯配置的效应量仅为 0.0030，对杭州二手房总价的区分能力十分有限。

切换至杭州租房样本后，各类变量的显著性与解释力度出现明显分化。物业类型 (0.0322) 和装修程度 (0.0298) 是影响月租金的核心因素，两者效应量相当且均高于二手房市场中的对应水平，说明在杭州租赁市场中，建筑形态与房屋品质对租金差异的解释作用超过交易市场。户型朝向 (0.0231) 和产权类型 (0.0162) 次之，楼层类型 (0.0114) 解释力较弱，电梯配置 (0.0009) 和产权年限 (0.0012) 的效应量极低。与二手房市场类似，产权类型对租房租金仍具有显著但较弱的解释力，反映租户对房屋法律权属类型的关注度虽有下降，但并未完全消失。整体而言，全部变量的效应量在租房样本中与二手房样本互有高低，不再呈现全样本中“所有变量均低于二手房”的统一规律，说明杭州市场的租赁价格形成机制具有不同于买卖市场的独立逻辑——装修程度和户型朝向在租房市场中的重要性更为突出。

4.3.5 金华市场变量关联与价格解释力分析

针对金华市场单独提取在售二手房、在租房源样本，重复开展连续变量相关性检验与分类变量单因素方差分析，挖掘金华本地市场的房价形成机制特征，与全样本、杭州市场形成横向对比。

连续变量相关性特征 图24与图25分别展示金华二手房、租房核心连续变量的皮尔逊相关系数热力矩阵。




图 24: 金华二手房变量相关性矩阵




图 25: 金华租房变量相关性矩阵

从金华二手房样本的关联特征来看，挂牌总价与建筑面积的皮尔逊相关系数达到0.83，不仅远高于三城合并全样本的0.53，也显著超过杭州市场的0.61，呈现强正向线性关联，说明在金华市场中，建筑面积对二手房挂牌总价的解释力度在三座城市中处于最高水平，是驱动本地二手房总价变动的绝对核心主导变量。而挂牌总价与房龄的相关系数仅为-0.07，数值无限趋近于零，二者完全不存在线性关联特征，房龄变量对金华二手房总价不具备线性层面的解释能力。建筑面积与房龄的相关系数为-0.08，同样几乎无线性相关，金华市场中户型面积与房龄不存在具备统计意义的绑定关系。

转向金华租房样本的相关性规律，月租金与建筑面积的相关系数为0.37，低于全样本租房场景的0.45，更远低于杭州市场的0.69，仅呈现中等偏弱的正向线性关联，意味着在金华租赁市场中，建筑面积对月租金水平的解释力度在三座城市中处于最低水平。月租金与房龄的相关系数为-0.03，二者线性关联近乎消失，房龄变量无法通过线性关系解释金华租赁价格的波动。建筑面积与房龄之间保持-0.05的极弱负相关，延续了全样本中老旧房源户型面积偏小的规律，但关联强度处于极低区间，不会诱发多重共线性问题。

分类变量单因素方差分析 以金华二手房挂牌总价、租房月租金分别作为因变量，对装修程度、电梯配置、楼层类型、物业类型、户型朝向、产权类型、产权年限开展单因素

方差分析，检验结果汇总于表7。

表 7: 金华市场分类变量 ANOVA 检验结果

房源类型	分类变量	F 统计量	p 值	效应量 η^2	有效样本量
二手房	decoration（装修程度）	75.29	1.13×10^{-48}	0.0196	10244
二手房	elevator（电梯配置）	10.10	0.0015	0.0009	10244
二手房	floor_type（楼层类型）	42.17	1.26×10^{-27}	0.0113	9349
二手房	property_type（物业类型）	289.37	0.0000	0.0987	10244
二手房	orientation（户型朝向）	86.24	2.34×10^{-156}	0.0412	10244
二手房	ownership_type（产权类型）	19.91	8.74×10^{-13}	0.0029	10244
二手房	property_years（产权年限）	21.35	4.19×10^{-14}	0.0031	10244
租房	decoration（装修程度）	32.14	5.72×10^{-21}	0.0087	8213
租房	elevator（电梯配置）	1.24	0.2652	0.0001	8213
租房	floor_type（楼层类型）	21.32	1.87×10^{-14}	0.0062	7646
租房	property_type（物业类型）	101.24	2.18×10^{-65}	0.0214	8213
租房	orientation（户型朝向）	6.71	1.25×10^{-9}	0.0031	8213
租房	ownership_type（产权类型）	10.11	1.47×10^{-7}	0.0015	8213
租房	property_years（产权年限）	1.01	0.3641	0.0002	8213

从金华二手房样本的检验结果来看，七类分类变量对应的 p 值均远小于 0.01，全部通过 1% 水平下的显著性检验，说明装修、电梯、楼层、物业、朝向、产权类型、产权年限均能够显著区分金华二手房挂牌总价的高低。对比各组效应量 η^2 可以发现，物业类型的效应量达到 0.0987，在所有分类变量中解释力度断层领先；户型朝向、装修程度次之，效应量分别为 0.0412、0.0196；楼层类型、产权年限、产权类型具备中等偏弱的解释作用；电梯配置的效应量仅为 0.0009，对金华二手房总价的区分能力十分有限。整体变量解释力度排序与杭州市场保持一致，但各类变量的效应量均略低于杭州市场，分类属性对金华二手房总价的解释作用弱于杭州。

切换至金华租房样本后，各类变量的显著性与解释力度出现明显分化。装修程度、楼层类型、物业类型、户型朝向、产权类型依旧在 1% 显著性水平下显著作用于月租金；产权年限对应的 p 值为 0.3641，未通过常规显著性检验；电梯配置对应的 p 值为 0.2652，同样未通过常规显著性检验，对租金的区分能力完全消失。整体解释力度排序与本地二手房保持一致，物业类型依旧是影响租金的核心分类变量，但全部变量的效应量均低于本地二手房样本，与全样本、杭州市场的规律保持统一，反映分类属性对金华二手挂牌总价的解释作用整体强于本地租赁市场。

4.3.6 临沂市场变量关联与价格解释力分析

针对临沂市场单独提取在售二手房、在租房源样本，开展全维度连续变量相关性检验与分类变量单因素方差分析，挖掘临沂本地市场的房价形成机制特征，与全样本、杭州、金华市场形成完整横向对比。

连续变量相关性特征 图26与图27分别展示临沂二手房、租房全维度核心连续变量的皮尔逊相关系数热力矩阵, 涵盖房价核心变量、租售比、配套总分及细分配套维度。




图 26: 临沂二手房变量相关性矩阵




图 27: 临沂租房变量相关性矩阵

从临沂二手房样本的关联特征来看，核心定价变量呈现以下规律：1. **** 房价与基础属性 ****：挂牌总价与建筑面积的皮尔逊相关系数达到 0.80，不仅远高于三城合并全样本的 0.53，也超过杭州市场的 0.61，与金华市场的 0.83 处于同一区间，呈现强正向线性关联，说明在临沂市场中，建筑面积对二手房挂牌总价的解释力度处于三座城市的第一梯队，是驱动本地二手房总价变动的绝对核心主导变量；挂牌总价与房龄的相关系数为 -0.14 ，呈现微弱负相关，仅能体现房龄偏老的二手房总价水平略低，整体线性关联强度极弱，房龄变量对临沂二手房总价不具备实质线性解释能力；建筑面积与房龄的相关系数为 -0.14 ，同样仅表现出极弱负相关，临沂市场中户型面积与房龄不存在具备统计意义的强绑定关系。2. **** 房价与租售比、配套水平 ****：挂牌总价与租售比、配套总分的相关系数分别为 -0.06 、 -0.04 ，均无限趋近于零，二者对二手房总价几乎无线性解释能力；细分配套维度中，地铁、学校、医院、商业、餐饮配套得分与二手房总价的相关系数均在 -0.04 0.02 区间，全部无显著线性关联，说明配套资源差异并非临沂二手房总价的线性影响因素。3. **** 变量间内在关联 ****：配套总分与学校配套得分的相关系数高达 0.88，与地铁配套得分的相关系数为 0.68，呈现强正向关联，说明临沂配套总分的差异主要由学校、地铁配套水平决定；房龄与学校配套得分的相关系数为 0.26，与配套总分的相关系数为 0.24，呈现弱正相关，体现临沂老旧小区整体配套资源相对更完善的特征。

转向临沂租房样本的相关性规律，核心定价逻辑与二手房市场呈现明显差异：1. **租金与基础属性**：月租金与建筑面积的相关系数为 0.68，高于全样本租房场景的 0.45 与金华市场的 0.37，但低于杭州市场的 0.69，呈现中等偏强的正向线性关联，意味着在临沂租赁市场中，建筑面积对月租金水平的解释力度处于三座城市的中间水平；月租金与房龄的相关系数为 -0.18，呈现微弱负相关，仅能体现房龄偏老的租赁房源租金水平

略低，整体线性关联强度极弱；建筑面积与房龄的相关系数为 -0.14 ，延续了老旧房源户型面积偏小的规律，但关联强度处于极低区间，不会诱发多重共线性问题。2. ** 租金与租售比、配套水平 **：月租金与租售比的相关系数为 -0.09 ，与配套总分的相关系数为 -0.10 ，均无显著线性关联；细分配套维度中，仅学校配套得分与月租金的相关系数为 -0.13 ，呈现极弱负相关，其余配套维度与租金的相关系数均在 -0.01 0.04 区间，无实质线性解释能力，说明配套资源对临沂租赁市场的租金定价影响同样极小。3. ** 变量间内在关联 **：租房样本中配套总分与学校配套得分的相关系数为 0.89 ，与地铁配套得分的相关系数为 0.60 ，与二手房市场保持一致，配套总分的差异仍由学校、地铁配套水平主导；建筑面积与学校配套得分的相关系数为 -0.28 ，呈现弱负相关，体现临沂小户型租赁房源更集中于学校配套完善的区域。

分类变量单因素方差分析 以临沂二手房挂牌总价、租房月租金分别作为因变量，对装修程度、电梯配置、楼层类型、物业类型、户型朝向、产权类型、产权年限开展单因素方差分析，检验结果汇总于表8。

表 8: 临沂市场分类变量 ANOVA 检验结果

房源类型	分类变量	F 统计量	p 值	效应量 η^2	有效样本量
二手房	decoration（装修程度）	42.18	1.25×10^{-27}	0.0113	9126
二手房	elevator（电梯配置）	7.23	0.0072	0.0007	9126
二手房	floor_type（楼层类型）	28.45	2.31×10^{-18}	0.0087	8342
二手房	property_type（物业类型）	186.72	0.0000	0.0762	9126
二手房	orientation（户型朝向）	56.37	3.24×10^{-102}	0.0321	9126
二手房	ownership_type（产权类型）	12.34	1.87×10^{-9}	0.0018	9126
二手房	property_years（产权年限）	10.21	3.42×10^{-8}	0.0015	9126
租房	decoration（装修程度）	21.33	1.86×10^{-14}	0.0062	7339
租房	elevator（电梯配置）	0.87	0.3512	0.0001	7339
租房	floor_type（楼层类型）	15.62	4.27×10^{-11}	0.0048	6857
租房	property_type（物业类型）	75.32	1.08×10^{-48}	0.0165	7339
租房	orientation（户型朝向）	4.21	3.17×10^{-6}	0.0021	7339
租房	ownership_type（产权类型）	8.76	1.24×10^{-6}	0.0013	7339
租房	property_years（产权年限）	0.92	0.3915	0.0001	7339

从临沂二手房样本的检验结果来看，七类分类变量对应的 p 值均远小于 0.01 ，全部通过 1% 水平下的显著性检验，说明装修、电梯、楼层、物业、朝向、产权类型、产权年限均能够显著区分临沂二手房挂牌总价的高低。对比各组效应量 η^2 可以发现，物业类型的效应量达到 0.0762 ，在所有分类变量中解释力度断层领先；户型朝向、装修程度次之，效应量分别为 0.0321 、 0.0113 ；楼层类型、产权类型、产权年限具备中等偏弱的解释作用；电梯配置的效应量仅为 0.0007 ，对临沂二手房总价的区分能力十分有限。整体变量解释力度排序与杭州、金华市场保持一致，但各类变量的效应量均低于杭州、金

华市场，分类属性对临沂二手房总价的解释作用在三座城市中处于最低水平，与临沂市场产品梯度单薄、价格分层弱的特征完全匹配。

切换至临沂租房样本后，各类变量的显著性与解释力度出现明显分化。装修程度、楼层类型、物业类型、户型朝向、产权类型依旧在 1% 显著性水平下显著作用于月租金；产权年限对应的 p 值为 0.3915，未通过常规显著性检验；电梯配置对应的 p 值为 0.3512，同样未通过常规显著性检验，对租金的区分能力完全消失。整体解释力度排序与本地二手房保持一致，物业类型依旧是影响租金的核心分类变量，且全部变量的效应量均低于本地二手房样本，与全样本、杭州、金华市场的规律保持统一，反映分类属性对临沂二手挂牌总价的解释作用整体强于本地租赁市场。

4.3.7 城市间差异检验

前文分别从全国汇总与分城市两个维度考察了变量间的关联特征，但尚未从统计上直接检验杭州、金华、临沂三城之间在核心变量上是否存在显著差异。为量化市场分化程度并回答子问题一中的“差异化信号”，本节采用单因素方差分析（ANOVA）检验连续变量在不同城市间的均值差异，辅以 Tukey HSD 事后检验识别具体差异来源；同时采用卡方检验考察分类变量在城市间的分布差异。二手房与租房样本分别独立检验。

连续变量城市间差异 以城市为分组变量，对二手房样本的总价、面积、房龄、租售比、总配套得分五个连续变量分别进行单因素方差分析，检验结果汇总于表13。

表 9: 二手房连续变量城市间 ANOVA 差异检验

变量	F 统计量	p 值	显著性	显著差异配对
total_price (总价/万元)	3136.19	0.0000	是	三城两两均显著
area (面积/㎡)	1122.90	0.0000	是	临沂-杭州、杭州-金华显著
house_age (房龄/年)	1469.30	0.0000	是	三城两两均显著
rent_sale_ratio (租售比)	62.89	5.78×10^{-28}	是	三城两两均显著
total_amenity_score (配套总分)	5378.82	0.0000	是	三城两两均显著

所有五个变量均通过 1% 显著性检验，表明二手房市场的各项核心指标在三座城市间均存在显著差异。从效应方向来看（表10），临沂二手房总价显著高于杭州和金华，而杭州又显著高于金华——这与三城经济发展水平的基本面排序（杭州 > 金华 > 临沂）并不一致，反映出临沂作为三线城市，其二手房挂牌总价偏高的反常现象，可能与临沂市场供给结构中以大面积房源为主有关。在面积方面，杭州平均面积显著低于其他两市，体现高能级城市“小户型高单价”的市场特征；金华与临沂之间面积差异不显著，两者同处相近的户型面积区间。房龄方面呈现“临沂 > 杭州 > 金华”的梯度，金华房龄最小，意味着该市存量房中次新房占比更高。租售比方面呈现“金华 > 杭州 > 临沂”的梯度，金华租售比最高，表明其租赁回报率在三城中相对合理；临沂租售比最低，反映

其二手房市场可能存在价格虚高或租赁需求不足的问题。配套得分方面呈现“杭州 > 金华 > 临沂”的梯度，与城市能级排序完全一致，高能级城市在公共配套资源上的集聚优势十分突出。

表 10: 二手房连续变量 Tukey HSD 事后检验显著配对汇总

变量	配对	均值差	p-adj
total_price	临沂-杭州	194.29	0.0000
total_price	临沂-金华	80.89	0.0000
total_price	杭州-金华	-113.39	0.0000
area	临沂-杭州	-31.42	0.0000
area	杭州-金华	32.30	0.0000
house_age	临沂-杭州	5.21	0.0000
house_age	临沂-金华	2.34	0.0000
house_age	杭州-金华	-2.88	0.0000
rent_sale_ratio	临沂-杭州	-0.36	0.0006
rent_sale_ratio	临沂-金华	-1.21	0.0000
rent_sale_ratio	杭州-金华	-0.84	0.0000
total_amenity_score	临沂-杭州	4.23	0.0000
total_amenity_score	临沂-金华	0.50	0.0000
total_amenity_score	杭州-金华	-3.73	0.0000

转向租房样本（表11），月租金、面积、房龄、总配套得分四个连续变量的城市间差异同样均通过 1% 显著性检验，说明租赁市场的城市间分化同样显著存在。

表 11: 租房连续变量城市间 ANOVA 差异检验

变量	F 统计量	p 值	显著性	显著差异配对
total_price（月租金/元）	2199.75	0.0000	是	三城两两均显著
area（面积/㎡）	487.08	3.56×10^{-207}	是	三城两两均显著
house_age（房龄/年）	44.61	4.68×10^{-20}	是	临沂-杭州、临沂-金华显著
total_amenity_score（配套总分）	5200.15	0.0000	是	三城两两均显著

从 Tukey 事后检验结果来看（表12），月租金呈现“临沂 > 杭州 > 金华”的梯度，与二手房总价的排序一致而非与城市能级一致，再次印证临沂租金水平相对偏高的特征。面积方面，杭州租房面积显著低于其他两市，与二手房规律一致。房龄方面，临沂房龄显著高于杭州和金华，而杭州与金华之间差异不显著，说明临沂租赁房源的楼龄普遍偏老。配套得分方面同样呈现“杭州 > 金华 > 临沂”的梯度，与二手房一致。

表 12: 租房连续变量 Tukey HSD 事后检验显著配对汇总

变量	配对	均值差	<i>p</i> -adj
total_price	临沂-杭州	1954.51	0.0000
total_price	临沂-金华	931.40	0.0000
total_price	杭州-金华	-1023.10	0.0000
area	临沂-杭州	-18.79	0.0000
area	临沂-金华	3.98	0.0001
area	杭州-金华	22.77	0.0000
house_age	临沂-杭州	1.02	0.0000
house_age	临沂-金华	1.04	0.0000
total_amenity_score	临沂-杭州	4.17	0.0000
total_amenity_score	临沂-金华	0.52	0.0000
total_amenity_score	杭州-金华	-3.65	0.0000

分类变量城市间分布差异 采用卡方检验考察各分类变量在三个城市间的分布是否存在显著差异，检验结果汇总于表13。

表 13: 二手房连续变量城市间 ANOVA 差异检验

变量	F 统计量	<i>p</i> 值	显著性	显著差异配对
total_price (总价/万元)	3136.19	0.0000	是	三城两两均显著
area (面积/㎡)	1122.90	0.0000	是	临沂-杭州、杭州-金华显著
house_age (房龄/年)	1469.30	0.0000	是	三城两两均显著
rent_sale_ratio (租售比)	62.89	5.78×10^{-28}	是	三城两两均显著
total_amenity_score (配套总分)	5378.82	0.0000	是	三城两两均显著

二手房样本中，五个分类变量均通过 1% 显著性检验，说明物业类型、装修程度、楼层类型、户型朝向、产权类型在三座城市间的分布结构存在显著差异。其中朝向的卡方统计量高达 11443.36，反映三城在户型朝向上的偏好和供给结构截然不同，这可能与不同城市的建筑规范、气候条件以及消费者偏好差异有关。产权类型的卡方统计量为 395.85，同样显著，表明不同能级城市在房屋产权结构上存在实质性差异。

租房样本中，五个分类变量的卡方检验同样全部显著，且装修程度的卡方统计量高达 2229.84，说明租赁市场中装修程度的城市间差异极为突出——高能级城市的租赁房源装修品质整体优于低能级城市。朝向（3096.34）的差异同样显著，与二手房一致。

综上，三座城市在连续变量均值和分类变量分布上均呈现显著差异，且这些差异在二手房与租房市场中均高度显著。这一结果从统计上证实了三城市场存在明显的结构性分化，也为后续分城市建模的必要性提供了直接证据：若将三城数据简单合并建模，城市间的系统性差异将构成严重的未观测异质性，导致模型估计偏误。因此，后续回归分

析与聚类分析均需充分考虑城市间的差异特征。

5 聚类分析

5.1 聚类思路与研究问题

在探索性分析中，本研究已通过描述性统计和可视化初步观察到不同城市、不同房源类型在价格、面积、房龄、配套等维度上的分布差异。然而，这些差异是否能够形成自然的数据分组？不同城市之间是否存在相似的市场结构？这些问题无法仅凭单变量分析回答，需要借助聚类方法从数据的多维特征中发现内在的分组模式。

聚类分析的核心目标在于：不依赖先验标签，仅依据房源自身的多维特征，将相似的房源归为一类，从而揭示住房市场内部的结构性分群。具体而言，本研究围绕以下问题展开：各城市的房源能否根据价格、房龄、租售比、配套、物业类型、装修、楼层、区位等特征划分为若干具有显著差异的群体？不同城市之间、二手房与租房之间是否存在相似或不同的聚类结构？

由于不同能级城市的住房市场可能存在差异化的定价逻辑和供需结构，本研究不对所有城市的数据进行统一聚类，而是采用分城市、分房源类型的策略，即对杭州二手房、杭州租房、金华二手房、金华租房、临沂二手房、临沂租房六个组合分别执行聚类分析。这一设计旨在保留各子市场的特异性，避免跨城市、跨类型的异质性对聚类结构的干扰，同时也使得后续的比较分析（如不同城市的聚类数差异、轮廓系数差异）具有清晰的对照基础。

在方法选择上，本研究采用 K-Prototypes 算法。该算法是 K-Means 的扩展，专为混合类型数据设计：对数值型特征使用欧氏距离，对类别型特征使用汉明距离（相同为 0，不同为 1），通过加权求和构建统一的相异度矩阵。相较于传统 K-Means 需要对类别变量进行 One-Hot 编码，K-Prototypes 直接使用原始类别值，避免了高维稀疏虚拟变量对距离计算的扭曲。这一特性使其天然适用于同时包含价格、房龄等数值变量和区位、物业类型、装修程度等分类变量的住房数据。

此外，本研究还尝试了基于 Gower 距离的层次聚类作为对比方法，以验证 K-Prototypes 结果的稳健性。两种方法互为参照，有助于更全面地判断聚类结构的可靠性。

5.2 特征选择与检验

聚类特征的选择采取“两步走”策略：首先基于探索性分析的统计检验结果进行初步筛选，剔除明确不具备区分能力的变量；然后在聚类前对保留的特征进行三项诊断检验——数值特征间的 Pearson 相关系数、类别特征间的 Cramér's V 系数、以及类别特征对数值特征的 ANOVA 区分度——根据检验结果最终确定聚类输入特征集。

第一步:基于 EDA 的初步筛选 数值特征方面,本研究初步选取四个核心变量:unit_price (单价)反映房屋的价值档次;house_age (房龄)表征房屋的新旧程度;rent_sale_ratio (租售比)表征小区的出租活跃度与投资属性,是回答“租售比错配”问题的核心变量;total_amenity_score (总配套得分)衡量小区周边的整体生活便利度。四个数值特征分别从价格水平、房屋品质、投资属性和区位配套四个维度刻画房源特征。

类别特征方面,ANOVA 结果显示,物业类型 (property_type) 的效应量 η^2 在全国二手房样本中高达 0.1295,在临沂二手房中更达到 0.540,是区分房源群体的最强变量,予以保留。楼层类型 (floor_type, 全国 0.0533)、装修程度 (decoration, 全国 0.0163) 在各城市中均保持显著,予以保留。产权类型 (ownership_type, 全国 0.0103) 效应量虽不及物业类型,但其表征房屋的法律权属属性(如纯商品住宅、保障/政策类住宅、商办类),与物业类型形成“物理形态—法律性质”的互补维度,且各城市均保持显著,亦予以保留。行政区 (district) 作为空间区位变量,在探索性分析中已展现出显著的组间差异,纳入初步特征集。

朝向 (orientation) 在全国二手房样本中效应量高达 0.0840,仅次于物业类型,位列第二,表明其在全国层面具有较强的区分潜力,但因城市之间在建筑规范、气候条件和消费者偏好上存在差异,需待聚类前诊断检验进一步确认其对聚类贡献的有效性和稳定性,故初选阶段予以保留。电梯 (elevator) 的效应量在全国二手房中仅为 0.0011,在租房市场中未通过显著性检验,区分能力极其有限,予以剔除。产权年限 (property_years) 效应量较低 (0.0084),且与房龄存在概念重叠,亦予剔除。

综上,初步保留的特征共四个数值变量(unit_price、house_age、rent_sale_ratio、total_amenity_score)与六个类别变量(property_type、decoration、floor_type、district、ownership_type、orientation),合计十维。

第二步:聚类前诊断检验 对于初步保留的特征,本研究在聚类前进一步执行三项诊断检验,以确认其是否满足聚类输入的要求。

数值特征间的 Pearson 相关系数。 K-Prototypes 对数值特征使用欧氏距离,若两个数值特征的相关系数 $|r| > 0.7$,则它们在距离计算中会重复加权相同的信息结构,导致聚类结果过度依赖某一维度而削弱其他特征的贡献。本研究计算了四个数值特征两两之间的 Pearson 相关系数。

类别特征间的 Cramér's V 系数。对于类别特征,若两个变量的 Cramér's V 系数 > 0.6 ,说明二者高度关联,携带相似的分组信息,同时纳入会造成冗余。本研究计算了六个类别特征两两之间的 Cramér's V 系数。

类别特征对数值特征的 ANOVA 区分度。该检验用于确认各分类变量是否在不同数值特征上具有显著的分组差异。对每个保留的类别特征,分别以四个数值特征为因变量进行单因素 ANOVA,若某类别特征在所有四个数值特征上的 p 值均大于 0.05,则说明该类别特征对数值特征不具备显著的分组区分能力,其对聚类的贡献可能有限,应考虑剔除。

上述三项诊断检验从共线性、冗余性和区分度三个角度对初步特征集进行综合评估。检验在六个组合上分别执行，结果汇总如表 14 所示。

表 14: 特征诊断结果汇总

分组	样本数	数值特征最大 $ r $	类别特征最大 Cramér's V	ANOVA 不显著比例
杭州 _ 二手房	9313	0.406	0.707	1/24
杭州 _ 租房	9247	0.341	0.707	1/24
金华 _ 二手房	6069	0.338	0.708	0/24
金华 _ 租房	3895	0.370	0.707	3/24
临沂 _ 二手房	8198	0.239	0.707	0/24
临沂 _ 租房	6471	0.113	0.707	5/24

注：ANOVA 不显著定义为 $p \geq 0.05$ 。

三项检验的具体结果如下。

数值特征相关性。六个组合的 Pearson 相关系数绝对值最大值在 0.113 至 0.406 之间，均远低于 0.7 的经验阈值，表明四个数值特征之间不存在共线性问题，四个数值特征均可保留。

类别特征关联性。六个组合的 Cramér's V 系数矩阵显示，property_type 与 ownership_type 在所有组合中的系数均约为 0.707，超过 0.6 的经验阈值，表明二者高度关联，携带相似的分组信息。从业务含义来看，property_type（物业类型）描述建筑的物理形态（如普通住宅、公寓、别墅），而 ownership_type（产权类型）描述房屋的法律权属性质（如纯商品住宅、保障/政策类住宅）。在本次数据中，绝大多数“普通住宅”对应“纯商品住宅”，“公寓”对应“商办类”，两者高度重合。由于物业类型在 ANOVA 中的效应量 ($\eta^2 = 0.1295$) 远高于产权类型 ($\eta^2 = 0.0103$)，因此剔除 ownership_type，保留 property_type。其余类别特征之间的 Cramér's V 系数均低于 0.5，不存在强关联问题。

类别-数值区分度。在剔除 ownership_type 后，剩余五个类别特征(property_type、decoration、floor_type、district、orientation) 对四个数值特征的 ANOVA 检验中，临沂租房和金华租房的不显著比例相对较高，分别为 5/24 和 3/24。这些不显著结果主要集中于两类情况：一是 decoration 与 rent_sale_ratio 在临沂租房 ($p = 0.105$) 和金华租房 ($p = 0.881$) 中的不显著，反映出在低能级城市的租赁市场中，装修程度对租售比的区分能力较弱——低能级城市租户对装修品质的支付意愿较低；二是 floor_type 与 unit_price 在金华租房 ($p = 0.792$) 和临沂租房 ($p = 0.547$) 中的不显著，以及 orientation 与 unit_price 在金华租房 ($p = 0.976$) 中的不显著，表明在低能级城市的租赁市场中，楼层和朝向对单价的区分能力较弱。这些不显著结果均与市场逻辑相符，反映的是低能级城市租房供给结构的相对单一性，而非特征选择错误。其余组合均在 0.05 水平上显著，五个类别特征的区分能力整体良好。

综合全部检验结果，ownership_type 因与 property_type 高度关联予以剔除，其余特征均通过诊断，最终聚类特征集为四个数值特征(unit_price、house_age、rent_sale_ratio、

total_amenity_score) 与五个类别特征 (property_type、decoration、floor_type、district、orientation)，合计九维，确保进入 K-Prototypes 算法的特征既具备信息独立性，又具有足够的组间区分能力。

5.3 聚类方法与结果分析

本研究采用 K-Prototypes 算法对六个组合分别进行聚类。最优聚类数通过轮廓系数确定，搜索范围为 $K = 2$ 至 $K = 8$ ，选择轮廓系数最大的 K 值，同时要求各簇样本占比不低于 5% 以避免过小簇。聚类结果如表 15 所示。

表 15: K-Prototypes 聚类结果汇总			
分组	最优 K	样本数	轮廓系数
杭州 _ 二手房	5	9313	0.298
杭州 _ 租房	5	9247	0.276
金华 _ 二手房	2	6069	0.298
金华 _ 租房	3	3895	0.366
临沂 _ 二手房	5	8198	0.287
临沂 _ 租房	4	6471	0.327

各组合轮廓系数介于 0.276 至 0.366 之间。考虑到住房数据天然呈现连续分布特征且存在大量噪声，该轮廓系数范围在房地产聚类研究中属于合理水平，表明聚类结果能够有效反映市场的结构性分群。从最优聚类数看，杭州和临沂的二手房最优 K 均为 5，杭州租房同样为 5，临沂租房为 4，而金华二手房仅为 2、金华租房为 3。金华最优聚类数显著低于其他两市，与 EDA 阶段金华市场内部同质化程度较高的发现一致——金华作为三线城市中经济体量最小的城市，住房产品结构与价格梯度相对单一，难以形成多样化的市场细分。从轮廓系数看，金华租房轮廓系数最高 (0.366)，临沂租房次之 (0.327)，杭州各组合相对较低 (0.276 ~ 0.298)，与 EDA 阶段高能级城市市场异质性更强、聚类边界相对模糊的特征吻合。

各组合聚类结果的簇解读如表 16 至 21 所示。

表 16: 杭州二手房各簇特征解读				
簇	样本数	占比	主要区位	特征描述
0	4414	47.4%	余杭区	均价均衡型，房龄较新，郊区改善/刚需主体
1	1858	20.0%	上城区	均价均衡型，房龄偏老，核心区老旧房源
2	106	1.1%	滨江区	均价均衡型，出租占比高，投资属性集中
3	1693	18.2%	余杭区	低单价次新实惠型，配套薄弱，价格洼地
4	1242	13.3%	滨江区	高单价次新品质型，核心区高端改善房源

杭州二手房共划分 5 个簇。簇 0 (47.4%) 与簇 3 (18.2%) 均集中在余杭区，前者为

均价均衡型、房龄较新，代表郊区改善型房源的主流群体；后者为低单价实惠型、配套薄弱，构成价格敏感型刚需的集聚。簇 4（13.3%）位于滨江区，呈现高单价、次新、配套完善的特征，代表核心区高端改善群体。簇 2（1.1%）占比极低，属于异常小簇，需谨慎解读。

表 17: 杭州租房各簇特征解读

簇	样本数	占比	主要区位	特征描述
0	1618	17.5%	余杭区	低单价次新实惠型，配套薄弱
1	2023	21.9%	上城区	均价均衡型，房龄偏老
2	4008	43.3%	临平区	中低单价型，郊区刚需租赁主体
3	10	0.1%	西湖区	商住楼，极低占比异常值
4	1588	17.2%	滨江区	高单价次新品质型，核心区高端租赁

杭州租房同样划分 5 个簇。簇 2（43.3%）位于临平区，呈现中低单价特征，是郊区刚需租赁的绝对主体；簇 1（21.9%）位于上城区，为房龄偏老的均价均衡型房源，代表核心区老旧租赁房源。簇 0（17.5%）与簇 4（17.2%）分别位于余杭区和滨江区，形成“低单价次新实惠—高单价次新品质”的两极分化格局。簇 3 仅 10 个样本，系商住楼异常值，后续分析中可予剔除。

表 18: 金华二手房各簇特征解读

簇	样本数	占比	主要区位	特征描述
0	2059	33.9%	婺城区	均价均衡型，房龄偏老，核心区老旧房源
1	4010	66.1%	婺城区	均价均衡型，房龄较新，市场主体

金华二手房仅划分 2 个簇，是所有组合中最少的。两簇均集中在婺城区，核心差异在于房龄：簇 0（33.9%）房龄偏老，代表核心区老旧存量房源；簇 1（66.1%）房龄较新，构成市场供给主体。两类房源在单价上均处于均值附近，不存在显著的价格分层，印证了金华二手房市场同质化程度较高的判断——市场缺乏高端改善与低价刚需的明显分化，产品结构较为单一。

表 19: 金华租房各簇特征解读

簇	样本数	占比	主要区位	特征描述
0	1377	35.4%	婺城区	均价均衡型，房龄偏老
1	160	4.1%	永康市	均价均衡型，出租占比高，占比偏低
2	2358	60.5%	婺城区	均价均衡型，房龄较新，市场主体

金华租房划分 3 个簇，但结构同样简单。簇 2（60.5%）和簇 0（35.4%）均集中于婺城区，核心差异仍为房龄——前者房龄较新构成主体，后者房龄偏老。簇 1（4.1%）位于永康市、出租占比较高，占比略低于 5% 的常规阈值，但其业务含义清晰（县级市租

赁投资型房源)，可选择性保留。金华租房同样未出现基于价格高低的显著分层，全部簇的单价标准化均值均接近 0，进一步验证了金华租赁市场的高度同质化。

表 20: 临沂二手房各簇特征解读

簇	样本数	占比	主要区位	特征描述
0	544	6.6%	北城新区	中高单价型，新城区改善房源
1	77	0.9%	兰山区	均价均衡，配套完善，出租占比高，异常小簇
2	3734	45.5%	兰山区	均价均衡型，房龄较新，市场主体
3	2086	25.4%	罗庄区	均价均衡型，配套薄弱
4	1757	21.4%	兰山区	中低单价型，房龄偏老

临沂二手房划分 5 个簇，呈现出比金华更丰富的市场结构。簇 2（45.5%）位于兰山区、房龄较新，构成市场供给主体；簇 3（25.4%）位于罗庄区、配套薄弱，代表郊区价格洼地；簇 4（21.4%）位于兰山区、房龄偏老，代表核心区老旧房源。簇 0（6.6%）位于北城新区、中高单价，是新城区改善型房源的集中体现。簇 1（0.9%）占比过低，属于异常小簇，需谨慎解读。

表 21: 临沂租房各簇特征解读

簇	样本数	占比	主要区位	特征描述
0	3050	47.1%	兰山区	均价均衡型，房龄较新，市场主体
1	1688	26.1%	兰山区	均价均衡型，房龄偏老
2	92	1.4%	兰山区	中高单价型，出租占比高，配套完善
3	1641	25.4%	罗庄区	均价均衡型，配套薄弱

临沂租房划分 4 个簇，结构清晰。簇 0（47.1%）位于兰山区、房龄较新，构成租赁市场供给主体；簇 1（26.1%）同样位于兰山区但房龄偏老，代表核心区老旧租赁房源；簇 3（25.4%）位于罗庄区、配套薄弱，代表郊区租赁房源。簇 2（1.4%）占比极低，虽呈现中高单价、出租占比高、配套完善的特征，但样本量过小，属于异常值。

在聚类效果的直观呈现上，本研究通过 PCA 将高维特征压缩至二维平面进行可视化。图 28 至 33 展示了六个组合的 PCA 聚类散点图，图 34 至 39 展示了对应的 K 值选择图（肘部图与轮廓系数图）。从 PCA 可视化结果可以看出，金华各组合的簇间分离最为清晰，与其较高的轮廓系数一致；杭州和临沂各组合的部分簇之间存在一定重叠，反映高能级城市市场内部异质性更强、聚类边界相对模糊的特征。K 值选择图显示，各组合的轮廓系数在最优 K 值处均达到峰值或拐点，肘部图在相应位置亦出现明显转折，验证了最优 K 值选择的合理性。




图 28: 杭州二手房 PCA 可视化




图 29: 杭州租房 PCA 可视化




图 30: 金华二手房 PCA 可视化




图 31: 金华租房 PCA 可视化




图 32: 临沂二手房 PCA 可视化




图 33: 临沂租房 PCA 可视化




图 34: 杭州二手房 K 值选择图




图 35: 杭州租房 K 值选择图




图 36: 金华二手房 K 值选择图




图 37: 金华租房 K 值选择图




图 38: 临沂二手房 K 值选择图




图 39: 临沂租房 K 值选择图

为验证 K-Prototypes 聚类结果的稳健性，本研究还尝试了基于 Gower 距离的层次聚类作为对比方法。两种方法的轮廓系数对比如表 22 所示。

表 22: 层次聚类与 K-Prototypes 轮廓系数对比

分组	K-Prototypes	层次聚类
杭州 _ 二手房	0.325	0.330
杭州 _ 租房	0.337	0.355
金华 _ 二手房	0.332	0.133
金华 _ 租房	0.383	0.068
临沂 _ 二手房	0.302	0.130
临沂 _ 租房	0.346	0.289

层次聚类结果呈现出两个显著特征。其一，所有组合的最优 K 值均为 2，这是由于层次聚类在 $K \geq 3$ 时普遍存在占比小于 5% 的极小簇，受平衡约束限制被自动跳过，最终强制采用 $K = 2$ 。其二，层次聚类的轮廓系数异常偏高，普遍在 0.9 以上——金华租房为 0.998、金华二手房为 0.999、临沂二手房为 0.992。这看似“聚类效果极佳”，但实际上恰恰暴露了层次聚类在本数据集中的失效：该算法将绝大部分样本聚为一个巨大簇（占比超过 99.9%），而将少量极端值单独成簇，形成了“一个背景簇加若干离群点”

的虚假结构。这种极端不均衡的聚类结果在轮廓系数上反而获得高分，因为离群点簇与背景簇之间的距离极远，从数学上推高了系数值，但这种高分并不代表有意义的市场分群。唯一例外是杭州各组合，其层次聚类轮廓系数与 K-Prototypes 相近（二手房 0.330 对 0.298，租房 0.355 对 0.276），反映出杭州住房数据的层级结构较为明显，可能与其多中心的空间发展格局有关——核心区、副城、郊区之间形成较为清晰的层级关系，层次聚类的树状结构恰好能够捕捉这种从中心到外围的自然层级。

总体而言，层次聚类在金华和临沂表现为“虚假的高轮廓系数 + 极端不均衡的簇结构”，其分群结果不具备业务解释力。本数据集的聚类结构更适合中心式聚类算法，K-Prototypes 通过同时优化数值特征的欧氏距离和类别特征的汉明距离，能更有效地捕捉混合类型数据的复杂结构，且各簇样本占比均衡、业务含义清晰。后续分析以 K-Prototypes 结果为准。

综合以上分析，本研究得出三条主要结论：

结论一：三个城市的住房市场均存在可辨识的结构性分群，但不同城市的分群复杂度差异明显。杭州和临沂的二手房与租房市场最优聚类数均为 4 至 5 个，市场细分较为充分；而金华二手房仅 2 个、金华租房仅 3 个，反映出低能级城市住房产品结构与价格梯度的相对单一性。分群的主要驱动力为单价（形成从核心区到郊区的价格梯度）和行政区（空间区位），房龄和配套在核心区与郊区的分化中起修饰性作用，而物业类型和装修程度在低能级城市中区分度有限。

结论二：不同能级城市的市场结构存在系统性差异。杭州作为高能级城市，其住房市场分化最为细致，核心区（上城/滨江）与郊区（余杭）之间形成明显的价格梯度，反映出城市多中心发展格局；金华作为中等城市，市场高度集中于主城区（婺城区）普通住宅，县域房源仅占少数，聚类结构最为简化；临沂作为低能级城市，市场以主城区（兰山区）为核心，新城区（北城新区）承担高端改善功能，外围区域（罗庄区）则代表配套薄弱的价格洼地。这一梯度格局与各城市的经济发展水平和城市化阶段相符。

结论三：不同房源类型的市场结构存在显著差异。租房市场的聚类结构普遍比二手房市场更为简化——杭州和临沂的租房市场最优聚类数均少于或等于二手房市场（杭州：5 vs 5，临沂：4 vs 5），金华租房（3 个）也少于二手房（2 个，但基准不同）。主流群体占比方面，租房市场同样更高（杭州租房 48.1% vs 杭州二手房 51.4%，但租房为 5 簇而二手房为 5 簇，需谨慎对比）。总体而言，租赁房源以中小户型普通住宅为主的供给特征，其多样性天然低于涵盖刚需、改善、豪宅等多层次的二手房市场，导致聚类结构更为简化、同质化程度更高。

本研究通过 `rent_sale_ratio`（在租房源数量/在售房源数量）发现：杭州与临沂售租比偏低（出租活跃），金华售租比偏高（自住为主），说明不同能级城市在住房持有用途上存在显著分化。但由于数据来源于安居客挂牌信息（非实际成交价），本研究未能从价格端（年租金/总价）严格检验投资回报率层面的租售比错配问题；从供给端出发的结构性错配分析，是本研究对该问题的核心贡献。

6 回归分析

6.1 回归思路与研究问题

回归分析的核心目标是量化各特征对房价和租金的边际贡献，并检验这些效应在不同能级城市之间是否存在系统性差异。具体而言，本研究围绕以下问题展开：面积、楼层、装修、电梯、物业类型、房龄、区位等特征对房价和租金的边际贡献如何？同一特征在不同城市间的效应是否一致？高能级城市的精装修溢价是否显著高于低能级城市？

由于二手房与租房的定价逻辑不同，且不同能级城市之间的市场结构存在差异，本研究不对所有数据进行统一建模，而是采用分城市、分房源类型的策略，分别建立六个独立的回归模型：杭州二手房、杭州租房、金华二手房、金华租房、临沂二手房、临沂租房。这一设计既保留了各子市场的特异性，也使得跨城市、跨类型的系数对比具有清晰的对照基础。

因变量的选择上，二手房模型采用单位面积价格（`unit_price`）并取对数，以消除面积对总价的规模效应，聚焦于房屋品质和区位价值对单价的影响；租房模型采用月租金（`total_price`）并取对数，因租客关注的是总支出而非单位面积成本。所有模型均采用 HC3 稳健标准误以处理异方差问题，并基于分城市、分类型的训练集进行拟合，在对应的测试集上评估泛化性能。模型拟合与评估的详细结果见后续章节。

6.2 特征选择与检验

回归模型的自变量筛选遵循与聚类一致的两步策略：首先基于探索性分析的统计检验结果与变量间的关联性诊断确定候选变量，并明确初步剔除的变量；然后通过多重共线性诊断（VIF）与残差诊断对候选变量进一步检验，根据诊断结果进行差异化调整，最终确定各组合的回归特征集。

第一步：基于 EDA 的初步筛选 候选变量的确定基于方差分析（ANOVA）的效应量 η^2 与变量间的关联性诊断，以此明确初步剔除的变量和待诊断确认的变量。

全国二手房样本中，物业类型（`property_type`）的效应量高达 0.1295，是解释价格差异的最强变量；楼层类型（`floor_type`, 0.0533）和装修程度（`decoration`, 0.0163）在各城市中均保持显著，予以保留。产权类型（`ownership_type`, 0.0103）的 Cramér's V 诊断显示其与 `property_type` 高度关联（ $V \approx 0.707$ ），为避免多重共线性直接剔除。产权年限（`property_years`, 0.0084）与房龄概念重叠，效应量较低，亦不纳入。

朝向（`orientation`）在全国二手房中效应量为 0.0840，位列第二，表明其在全国层面具有较强的区分潜力；但其分城市效应量差异较大（杭州 0.010、金华 0.008、临沂 0.016），需通过后续共线性诊断进一步判断保留价值，故进入候选集。电梯（`elevator`）效应量仅为 0.0011，在租房市场中未通过显著性检验，区分能力有限，但其作为建筑品质的二值指标在回归中可直接检验边际贡献，故暂予保留，交由诊断检验确认。

数值变量方面，二手房模型因因变量为 `unit_price`（单价），为避免面积对单价的规模效应干扰，排除 `area`；租房模型因因变量为 `total_price`（月租金），租客关注总支出，故保留 `area`。`house_age`（房龄）作为核心变量予以保留。行政区（`district`）在探索性分析中已展现出显著的组间差异，纳入候选集。

综上，初步确定的候选变量如表 23 所示。

表 23: 回归候选变量（初步筛选后）

变量类型	具体变量	备注
数值变量	<code>area</code>	仅租房模型保留
数值变量	<code>house_age</code>	两模型均保留
二值变量	<code>elevator_encoded</code>	待 VIF 诊断确认
类别变量 (One-Hot)	<code>district_*</code>	两模型均保留
类别变量 (One-Hot)	<code>floor_type_*</code>	两模型均保留
类别变量 (One-Hot)	<code>decoration_*</code>	两模型均保留
类别变量 (One-Hot)	<code>property_type_*</code>	两模型均保留
类别变量 (One-Hot)	<code>orientation_*</code>	待 VIF 诊断确认
剔除变量: <code>ownership_type</code> 、 <code>property_years</code> 、 <code>total_amenity_score</code> 、 <code>rent_sale_ratio</code> 、 <code>price</code> 、 <code>nsh</code> 、 <code>nrp</code> 、 <code>around_*</code> 等		

其中，`orientation_*` 和 `elevator_encoded` 虽进入候选集，但其最终去留由第二步的共线性诊断（VIF）决定。`decoration_*` 的具体编码方式（如是否合并精装修与简单装修）亦由诊断结果调整。

第二步：回归前诊断检验 对于初步保留的候选变量，本研究在回归前进一步执行多重共线性诊断（VIF），以识别和排除可能导致模型不稳定的高度相关变量，处理标准为 $VIF > 10$ 视为存在较强共线性，需剔除或合并相关变量。各组合的 VIF 诊断结果如表 24 所示。

表 24: 各组合 VIF 诊断结果 (原始值)

分组	高 VIF 变量 (原始值)	最高 VIF
杭州 _ 二手房	greening_rate(22.90)	30.80
	decoration_ 精装修 (13.33)	
	plot_ratio(10.05)	
	orientation_ 南 (30.80)	
杭州 _ 租房	greening_rate(25.00)	110.39
	plot_ratio(11.64)	
	decoration_ 简单装修 (13.20)	
	decoration_ 精装修 (110.39)	
	orientation_ 南 (76.81)	
金华 _ 二手房	greening_rate(27.36)	35.38
	plot_ratio(12.51)	
	orientation_ 南北 (35.38)	
金华 _ 租房	greening_rate(38.81)	100.69
	plot_ratio(15.47)	
	decoration_ 精装修 (100.69)	
	decoration_ 豪华装修 (29.47)	
	orientation_ 南 (36.75)	
	orientation_ 南北 (29.05)	
临沂 _ 二手房	greening_rate(32.40)	37.88
	plot_ratio(11.36)	
	orientation_ 南北 (37.88)	
临沂 _ 租房	greening_rate(34.85)	113.33
	plot_ratio(11.04)	
	district_ 兰山 (24.64)	
	district_ 北城新区 (14.53)	
	district_ 罗庄 (11.01)	
	decoration_ 简单装修 (24.22)	
	decoration_ 精装修 (113.33)	
	orientation_ 南 (29.31)	
	orientation_ 南北 (19.52)	

诊断结果显示, 各组合的共线性问题呈现以下规律:

第一, greening_rate (绿化率) 与 plot_ratio (容积率) 在所有组合中 VIF 均超过 10 (绿化率 22.90 至 38.81, 容积率 10.05 至 15.47), 表明这两个小区品质指标与行政区变量高度相关——不同行政区的土地开发强度和绿化标准存在系统性差异。由于 district 已在模型中作为核心区位特征保留, 各组合均剔除这两个变量。

第二, 朝向变量 (orientation_ 南或 orientation_ 南北) 在各组合中 VIF 均超

过 29，最高达 76.81。核心区房源更可能朝南或南北通透，导致朝向信息与行政区信息高度重叠。各组合均剔除所有朝向变量。

第三，`decoration_` 精装修在租房模型中 VIF 极高（100.69 至 113.33），远超二手房模型（4.89 至 13.33）。这反映出租房市场中精装修是绝对主流，与简单装修、豪华装修形成高度共线。据此，本研究对租房模型采取合并策略：将简单装修合并到精装修，仅保留“精装修（含简单装修）”和“豪华装修”两类；金华租房因豪华装修 VIF 达 29.47，将豪华装修一并合并到精装修。临沂租房中 `decoration_` 简单装修 VIF 为 24.22，亦通过合并解决。二手房模型因装修 VIF 均在可接受范围内（最高 13.33），故保留原始装修分类。

第四，临沂租房模型中 `district_` 兰山（24.64）、`district_` 北城新区（14.53）和 `district_` 罗庄（11.01）VIF 超过 10，反映出临沂租房市场中房源高度集中于兰山区及周边区域。由于 `district` 作为核心区位变量无法剔除，本研究保留这些变量，但需在回归结果解读时注意其标准误可能被放大。

基于上述诊断结果，各组合最终保留的自变量如表 25 所示。

表 25: 各组合最终保留的自变量

分组	最终保留特征
杭州 __ 二手房	house_age district_* floor_type_* decoration_* (原始分类) property_type_*
杭州 __ 租房	area house_age district_* floor_type_* decoration_* (精装含简单装) property_type_*
金华 __ 二手房	house_age district_* floor_type_* decoration_* (原始分类) property_type_*
金华 __ 租房	area house_age district_* floor_type_* decoration_* (精装含简单装和豪装) property_type_*
临沂 __ 二手房	house_age district_* floor_type_* decoration_* (原始分类) property_type_*
临沂 __ 租房	area house_age district_* floor_type_* decoration_* (精装含简单装) property_type_*

除共线性诊断外, 本研究还进行了残差诊断。各组合的 Breusch-Pagan 同方差性检验均未通过 ($p < 0.001$), 表明模型存在异方差, 因此所有回归均采用 HC3 稳健标准误进行统计推断, 以确保系数显著性检验的可靠性。Durbin-Watson 检验显示各组合 DW

统计量均介于 1.95 至 2.02 之间，表明残差无自相关问题。Shapiro-Wilk 正态性检验虽未通过，但考虑到各组合样本量均超过 2000 条，中心极限定理保证了系数估计量的渐进正态性，因此正态性假设可适当放宽。

6.3 回归模型与分析

本研究对六个组合分别建立多元线性回归模型，统一采用以下形式：

$$\ln(\text{Price}) = \beta_0 + \sum_{i=1}^p \beta_i X_i + \varepsilon$$

其中 $\ln(\text{Price})$ 为因变量的自然对数， β_0 为截距项， X_i 为第 i 个自变量， β_i 为其回归系数， ε 为误差项。所有模型均采用 HC3 稳健标准误估计系数的标准误，以处理异方差问题。六个模型的拟合优度汇总如表 26 所示。

表 26: 各回归模型拟合优度汇总

模型	R^2_{train}	R^2_{test}	ΔR^2	n_{train}	n_{test}	p
杭州 _ 二手房	0.766	0.756	0.010	6519	2794	20
杭州 _ 租房	0.749	0.743	0.006	6472	2775	17
金华 _ 二手房	0.534	0.520	0.014	4248	1821	16
金华 _ 租房	0.644	0.709	-0.064	2726	1169	12
临沂 _ 二手房	0.707	0.712	-0.005	5738	2460	21
临沂 _ 租房	0.682	0.713	-0.031	4529	1942	20

从拟合优度来看，杭州二手房与租房模型的测试 R^2 分别为 0.756 和 0.743，在所有模型中表现最佳，表明高能级城市的房价形成机制更为规范和可预测。临沂二手房与租房模型的测试 R^2 为 0.712 和 0.713，同样表现良好。金华二手房模型的测试 R^2 仅为 0.520，是所有模型中最低的，反映金华住房市场内部同质化程度较高，线性模型难以捕捉其价格差异的主要来源。金华租房模型表现居中（测试 $R^2 = 0.709$ ），与聚类分析中金华租房轮廓系数最高、市场结构清晰的结论一致。各模型的训练集与测试集 R^2 差距均在 0.07 以内，不存在严重过拟合问题。

各模型的具体方程与系数解读如下。

(一) 杭州二手房模型

$$\begin{aligned}
\ln(\text{unit_price}) = & 0.6675^{***} \\
& - 0.0043^{***} \cdot \text{house_age} \\
& + 0.1463^{***} \cdot \text{decoration_简单装修} \\
& + 0.1840^{***} \cdot \text{decoration_精装修} \\
& + 0.1806^{***} \cdot \text{decoration_豪华装修} \\
& + 0.3064^{***} \cdot \text{property_type_别墅} \\
& - 0.2443^{***} \cdot \text{property_type_商住楼} \\
& + \sum_k \gamma_k \cdot \text{district}_k
\end{aligned}$$

其中 $R^2_{\text{test}} = 0.756$, $n = 9313$, $p = 20$ 。测试 R^2 与训练集 R^2 (0.766) 差距仅 0.010, 表明模型泛化能力良好。

各行政区系数 γ_k 如表 27 所示, 所有系数均以拱墅区为参照组。

表 27: 杭州二手房行政区系数

行政区	系数	p 值	百分比影响
滨江	-0.0218	0.102	不显著
西湖	-0.1417	<0.001	-13.21%
萧山	-0.2678	<0.001	-23.49%
余杭	-0.3485	<0.001	-29.42%
钱塘	-0.3561	<0.001	-29.96%
临平	-0.5368	<0.001	-41.54%
富阳	-0.6954	<0.001	-50.11%
临安	-0.8833	<0.001	-58.66%
桐庐	-0.9323	<0.001	-60.63%

参照组拱墅区是杭州房价最高的行政区之一。以拱墅区为基准, 核心区 (滨江、西湖) 房价与之相近, 差距在 2% 至 13% 之间; 近郊 (萧山、余杭、钱塘) 低 23% 至 30%; 远郊 (临平、富阳、临安、桐庐) 低 42% 至 61%, 呈现从核心区到远郊的清晰价格梯度。

(二) 杭州租房模型

$$\begin{aligned}
\ln(\text{total_price}) = & 6.6571^{***} \\
& + 0.0129^{***} \cdot \text{area} \\
& - 0.0034^{***} \cdot \text{house_age} \\
& + 0.5479^{***} \cdot \text{decoration_精装修} \\
& + 0.7152^{***} \cdot \text{decoration_豪华装修} \\
& + 0.2175^{***} \cdot \text{property_type_商住楼} \\
& + \sum_k \gamma_k \cdot \text{district}_k
\end{aligned}$$

其中 $R_{\text{test}}^2 = 0.743$, $n = 9247$, $p = 17$ 。

各行政区系数 γ_k 如表 28 所示：

表 28: 杭州租房行政区系数

行政区	系数	p 值	百分比影响
滨江	-0.0848	<0.001	-8.13%
拱墅	-0.1003	<0.001	-9.54%
西湖	-0.2466	<0.001	-21.86%
萧山	-0.3519	<0.001	-29.66%
余杭	-0.3762	<0.001	-31.35%
钱塘	-0.3268	<0.001	-27.88%
临平	-0.6094	<0.001	-45.63%
富阳	-0.7453	<0.001	-52.54%
临安	-0.8241	<0.001	-56.13%

与二手房相比，租房市场的行政区梯度同样清晰但相对平缓——核心区与远郊最大差距约为 56%，低于二手房市场的 61%。与二手房不同，杭州租房模型中拱墅区的租金并非最高，滨江区与拱墅区租金最为接近。

（三）金华二手房模型

$$\begin{aligned}
\ln(\text{unit_price}) = & -0.2822^{***} \\
& - 0.0009 \cdot \text{house_age} \\
& + 0.1395^{***} \cdot \text{decoration_简单装修} \\
& + 0.1321^{***} \cdot \text{decoration_精装修} \\
& + 0.1993^{***} \cdot \text{decoration_豪华装修} \\
& - 0.2268^{***} \cdot \text{property_type_别墅} \\
& - 0.3412^{***} \cdot \text{property_type_商住楼} \\
& + \sum_k \gamma_k \cdot \text{district}_k
\end{aligned}$$

其中 $R^2_{\text{test}} = 0.520$, $n = 6069$, $p = 16$ 。房龄不显著 ($p = 0.219$)。
各行政区系数 γ_k 如表 29 所示：

表 29: 金华二手房行政区系数			
行政区	系数	p 值	百分比影响
婺城	0.0542	<0.001	+5.57%
武义县	0.0881	<0.001	+9.21%
永康	0.1362	<0.001	+14.60%
金东	-0.0073	0.613	不显著
兰溪	-0.1010	<0.001	-9.61%
浦江县	-0.0309	0.208	不显著

金华二手房市场中，永康房价显著高于主城区婺城（+14.6%），武义县和婺城也高于基准，金东与主城区差异不显著，兰溪房价显著低于主城区（-9.6%）。整体来看，金华行政区间的价格分化远弱于杭州，符合三线城市市场结构相对单一的判断。

（四）金华租房模型

$$\begin{aligned} \ln(\text{total_price}) = & 6.1336^{***} \\ & + 0.0082^{***} \cdot \text{area} \\ & - 0.0116^{***} \cdot \text{house_age} \\ & + 0.0337^{***} \cdot \text{floor_type_高层} \\ & - 0.2242^{***} \cdot \text{floor_type_未知} \\ & + 0.9332^{***} \cdot \text{decoration_精装修} \\ & - 0.0575^{**} \cdot \text{property_type_商住楼} \\ & + \sum_k \gamma_k \cdot \text{district}_k \end{aligned}$$

其中 $R^2_{\text{test}} = 0.709$, $n = 3895$, $p = 12$ 。值得注意的是，金华租房模型的测试 R^2 高于训练集 R^2 (0.644)，表明模型在测试集上的表现略优于训练集，可能存在训练集样本量较小导致的采样偏差。
各行政区系数 γ_k 如表 30 所示：

表 30: 金华租房行政区系数			
行政区	系数	p 值	百分比影响
永康	0.0387	0.139	不显著
婺城	-0.1951	<0.001	-17.72%
兰溪	-0.0989	<0.001	-9.42%
金东	-0.3077	<0.001	-26.48%

金东区租金显著低于主城区婺城（-26.5%），兰溪次之（-9.4%），永康与婺城差异不显著。

（五）临沂二手房模型

$$\begin{aligned} \ln(\text{unit_price}) = & -0.9198^{***} \\ & -0.0116^{***} \cdot \text{house_age} \\ & -0.0314^{**} \cdot \text{decoration_简单装修} \\ & +0.0439^{***} \cdot \text{decoration_精装修} \\ & +0.0563 \cdot \text{decoration_豪华装修} \\ & -0.4117^{***} \cdot \text{property_type_别墅} \\ & -0.1426^{***} \cdot \text{property_type_商住楼} \\ & + \sum_k \gamma_k \cdot \text{district}_k \end{aligned}$$

其中 $R_{\text{test}}^2 = 0.712$, $n = 8198$, $p = 21$ 。豪华装修不显著（ $p = 0.243$ ）。

各行政区系数 γ_k 如表 31 所示：

表 31: 临沂二手房行政区系数

行政区	系数	p 值	百分比影响
北城新区	0.3366	<0.001	+40.01%
兰山	0.2474	<0.001	+28.06%
费县	0.2713	<0.001	+31.16%
平邑	0.1881	<0.001	+20.70%
河东	0.1822	<0.001	+19.99%
沂水	0.1386	<0.001	+14.86%
莒南	0.0601	<0.001	+6.20%
开发区	0.0494	<0.01	+5.07%
罗庄	0.0285	<0.10	+2.89%（边际）
兰陵	-0.0701	<0.001	-6.77%

北城新区是临沂房价最高的区域（较基准高 40%），作为新城区承担高端改善功能。费县和兰山同样具有显著正溢价（+31% 和 +28%），反映临沂市场多中心的空间格局。罗庄区仅边际显著（ $p = 0.059$ ），兰陵县房价显著低于基准。

（六）临沂租房模型

$$\begin{aligned}\ln(\text{total_price}) = & 6.1688^{***} \\ & + 0.0112^{***} \cdot \text{area} \\ & - 0.0070^{***} \cdot \text{house_age} \\ & + 0.0679^{***} \cdot \text{floor_type_高层} \\ & + 0.2663^{***} \cdot \text{property_type_商住楼} \\ & + \sum_k \gamma_k \cdot \text{district}_k\end{aligned}$$

其中 $R^2_{\text{test}} = 0.713$, $n = 6471$, $p = 20$ 。装修类别和别墅均不显著，已剔除。
各行政区系数 γ_k 如表 32 所示：

表 32: 临沂租房行政区系数

行政区	系数	p 值	百分比影响
北城新区	0.0686	0.171	不显著
河东	0.0268	0.602	不显著
费县	0.0957	0.186	不显著
兰山	-0.0577	0.252	不显著
兰陵	-0.2447	<0.001	-21.71%
平邑	-0.1498	<0.01	-13.91%
开发区	-0.1553	<0.01	-14.39%
沂水	-0.1321	<0.05	-12.38%
罗庄	-0.1360	<0.01	-12.71%
莒南	-0.3058	<0.001	-26.34%
郯城	-0.0572	0.398	不显著

与二手房不同，临沂租房市场中仅兰陵、莒南、平邑、开发区、沂水、罗庄等外围区县显著低于基准，核心区（兰山、北城新区、河东）的系数均不显著。这表明租房市场的区位溢价远弱于二手房市场——租客对区位的支付意愿显著低于购房者。

综合六个模型的结果，本研究得出以下主要结论：

结论一：房龄对房价和租金均产生显著负向影响，低能级城市的房龄折价更大。临沂二手房房龄每增加一年单价下降 1.16%，杭州为 0.43%，金华房龄不显著。租房市场中，金华房龄折价最大（1.16% / 年），临沂次之（0.70% / 年），杭州最小（0.34% / 年）。这一梯度与城市能级呈反向关系，表明低能级城市住房市场对房屋物理折旧更为敏感，购房者和租客对老旧房屋的接受度更低。

结论二：精装修溢价随城市能级递减，且在租房市场中更为突出。杭州租房精装修溢价高达 72.95%，杭州二手房精装修溢价 20.20%，金华二手房 14.12%，临沂二手房精装修溢价仅 4.49%（豪华装修不显著）。临沂租房市场中装修类别完全不显著。高能级

城市的租客对“拎包入住”的支付意愿远强于低能级城市，而低能级城市租客更关注基础租金水平，对装修品质不敏感。

结论三：二手房与租房市场的定价逻辑存在本质差异。面积对租房月租金影响显著(弹性 0.82% ~ 1.30%)，但二手房因变量为单价，面积已被排除，其影响通过单价间接体现。行政区效应在二手房市场中更为陡峭——杭州核心区与远郊二手房单价差距达 61%，而在租房市场中仅 56%。临沂二手房中北城新区溢价 40%，但在租房市场中不显著。这表明购房者对区位的支付溢价显著高于租客。

结论四：城市能级越低，部分核心特征的解释力越弱。金华二手房模型的测试 R^2 仅 0.520，远低于杭州 (0.756) 和临沂 (0.712)，房龄和多个行政区系数不显著。这与聚类分析中金华市场结构最为简化的结论一致——住房产品高度同质化，线性模型难以捕捉其价格差异的主要来源。杭州各模型解释力最强，反映高能级城市的房价形成机制更为规范和可预测。

结论五：临沂商住楼呈现“租买分化”特征。临沂二手房市场中商住楼单价显著低于普通住宅 (-14.26%)，但在租房市场中商住楼租金显著高于普通住宅 (+30.51%)。这可能源于商住楼通常位于核心地段、以小户型为主，适合租赁但转售流动性较差，形成了“买低租高”的市场分化。

7 预测模型

7.1 预测思路与模型设定

预测分析的核心目标并非重复回归分析对边际效应的解释，而是从预测精度和特征重要性两个维度补充验证前文结论。具体而言，本研究围绕以下问题展开：基于跨城市可比的特征集，非线性模型能否达到较高的预测精度？特征重要性排序是否与回归系数方向一致？通过回答这些问题，预测分析为前文的回归结论提供稳健性验证。

与回归分析不同，预测分析采用全局建模策略，将三城市数据合并训练，以检验跨城市统一特征集的预测潜力。然而，全局建模面临一个核心挑战：如何构造跨城市可比的特征集？不同城市的行政区划完全不同，杭州的“上城区”与临沂的“兰山区”在空间尺度、人口密度、经济地位上并不等价，若直接将各城市的行政区虚拟变量合并入全局模型，会产生大量不可比的虚拟变量，不仅导致维度膨胀，还会让模型学到“城市间的行政区名称差异”而非“区位价值的本质差异”。为此，本研究在预测特征构造上做了两项关键的抽象化处理。

第一项抽象化处理是将行政区抽象为 `is_core`（是否核心区）二值变量。这一抽象的可行性源于聚类分析的结果。在聚类分析中，本研究已经识别出每个城市内部的“核心区”与“非核心区”的空间分化模式——核心区通常为城市中发展成熟、配套完善、房价最高的区域，而非核心区则包括近郊、远郊及县域。基于聚类结果对各城市行政区的核心区标签进行人工校验与确认后，本研究将各城市的行政区统一映射为“核心区 = 1，

非核心区 =0”的二值变量。这一映射使得跨城市的区位比较成为可能：核心区的区位溢价在不同城市之间具有可比性，而具体的行政区名称差异被抽象为“是否属于核心区”这一通用维度。is_core 在特征重要性中的表现也验证了这一抽象的有效性——在两个市场中均排名前列，说明这一简化确实捕捉到了核心区位对价格的稳定贡献。

第二项抽象化处理是构造 remaining_lease（剩余产权年限）特征，将产权年限与房龄合并为单一数值变量，计算公式为：

$$\text{remaining_lease} = \text{property_years} - \text{house_age}$$

其中 property_years 为土地使用权法定年限（40、50 或 70 年），house_age 为房屋已使用年限。这一特征构造基于两个考虑。其一，产权年限与房龄在业务含义上高度相关但各有侧重：房龄反映的是房屋物理品质的折旧，产权年限反映的是土地使用权价值的衰减。在房价形成机制中，购房者真正关心的是“剩余多少年的土地使用权”，而非单独关注原始产权年限或已使用年限。将两者合并为一个变量，既捕捉了“剩余土地使用价值”这一经济学含义，又避免了在模型中将两个高度相关的变量同时纳入而引发共线性问题。其二，不同城市之间存在产权结构的系统性差异——杭州的非 70 年产权房源占比高于金华和临沂，如果仅用产权年限或房龄单独建模，这部分城市间的制度性差异无法被有效捕捉；而 remaining_lease 作为一个连续变量，能够更精细地刻画从“全新 70 年产权”到“老旧 40 年产权”的完整梯度。剩余产权年限在不同城市间的分布差异，实质上反映了城市用地政策的多元性及其对住房价值的影响。

除上述两个核心构造特征外，所有多分类变量（city、property_type、decoration、floor_type）统一采用 Label Encoding 编码为有序整数，以避免 One-Hot 编码带来的维度膨胀和跨城市不可比问题。最终参与建模的七个特征如表 33 所示。

表 33: 预测模型特征集

特征	类型	说明
remaining_lease	数值	剩余产权年限 = property_years - house_age
is_core	二值	是否核心区（1= 核心区，0= 非核心区）
area	数值	建筑面积（m²）
city_code	数值	城市能级编码（杭州 =2，金华 =1，临沂 =0）
property_type_code	数值	物业类型编码（普通住宅 =0，公寓 =1，别墅 =2，商住楼 =3）
decoration_code	数值	装修程度编码（毛坯 =0，简装 =1，精装 =2，豪装 =3）
floor_type_code	数值	楼层类型编码（低层 =0，中层 =1，高层 =2）

模型选择上，采用随机森林与 XGBoost 两种主流集成学习算法，并进一步构建简单平均集成模型（RF + XGBoost）/ 2。三个模型形成“Bagging vs Boosting vs 融合”的完整对比。所有模型均基于训练集进行网格搜索超参数调优，在测试集（30% 样本）上评估泛化性能。因变量为 ln(unit_price)（二手房）和 ln(total_price)（租房）。

7.2 预测性能对比

各模型在测试集上的预测性能如表 34 所示。

表 34: 各模型预测性能对比 (测试集)				
市场	模型	RMSE	MAE	R^2
二手房	随机森林	0.335	0.260	0.793
	XGBoost	0.333	0.257	0.795
	集成 (RF+XGB)	0.332	0.258	0.796
租房	随机森林	0.267	0.190	0.862
	XGBoost	0.269	0.198	0.859
	集成 (RF+XGB)	0.264	0.191	0.865

从预测性能来看，两个市场均取得良好的预测精度。二手房市场测试 R^2 达到 0.796，租房市场达到 0.865，说明基于七个跨城市可比特征的非线性模型能够有效预测住房价格。租房市场预测精度显著高于二手房市场 (R^2 差距约 0.07)，与回归分析的发现一致——租赁市场的定价逻辑更为标准化，受租客对面积、区位等客观因素的驱动，而二手房市场受装修风格、业主心态等主观因素影响更大，噪声更多。

从模型对比来看，集成模型在两个市场中均略优于单一模型 (二手房 +0.001，租房 +0.003)，说明随机森林与 XGBoost 的融合能够互补各自的误差。XGBoost 与随机森林的差距极小，表明两种集成范式在本数据集上的表现高度一致，预测结论具有稳健性。

7.3 特征重要性分析

基于 XGBoost 与随机森林的增益重要性 (Gain Importance)，取两种模型重要性的平均值作为综合重要性排序。两个市场的特征重要性如表 35 所示。

表 35: 特征重要性排序				
特征	二手房		租房	
	重要性	排名	重要性	排名
city_code (城市能级)	0.865	1	0.604	1
area (面积)	0.037	3	0.304	2
is_core (核心区)	0.050	2	0.032	3
remaining_lease (剩余产权)	0.021	4	0.031	4
property_type_code (物业类型)	0.015	5	0.007	7
decoration_code (装修程度)	0.009	6	0.011	6
floor_type_code (楼层类型)	0.004	7	0.011	5

特征重要性揭示以下规律：

城市能级是最强的预测因子。 `city_code` 在两个市场中均排名第一，二手房市场重要性高达 0.865，租房市场为 0.604。这说明城市间的系统性差异（经济发展水平、供需结构、政策环境）是决定房价和租金的最核心因素，远超房源个体特征的影响。这一发现与聚类分析中“分城市建模必要”的结论形成互证，也解释了为什么回归分析中分城市建模的 R^2 存在显著差异。

面积在租房市场中重要性突出。 `area` 在租房市场中排名第二 (0.304)，但在二手房市场中仅排名第三 (0.037)。这印证了回归分析的结论——租房市场中面积是决定月租金的绝对核心因素，租客按面积付费的逻辑非常清晰；而在二手房市场中，因变量为单价，面积的影响通过单价间接体现，因此重要性相对降低。

核心区抽象有效。 `is_core` 在两个市场中均排名前列（二手房第 2，租房第 3），说明基于聚类结果将行政区抽象为“核心区/非核心区”的二值变量是有效的。这一设计解决了跨城市行政区不可比的问题，同时保留了最核心的区位信息——核心区溢价在两个市场中均稳定存在。

剩余产权年限具有独立贡献。 `remaining_lease` 在二手房中排名第 4 (0.021)，租房中排名第 4 (0.031)，说明土地使用权剩余期限对房价和租金均具有独立的边际解释力，验证了构造该特征的学术价值。在二手房市场中，剩余产权年限反映房屋的长期价值衰减；在租房市场中，它反映租客对房屋法律状态的隐性关注。

7.4 小结

综合预测分析的结果，本研究得出以下结论：

结论一：仅用七个跨城市可比的特征即可达到较高的预测精度。 二手房测试 R^2 为 0.796，租房测试 R^2 为 0.865，说明抽象化后的特征集（剩余产权年限、核心区指示、城市能级编码等）成功保留了住房定价的核心信息，特征工程的简化策略是有效的。

结论二：城市能级是最强的价格预测因子。 `city_code` 在两个市场中均排名第一，重要性显著高于房源个体特征，再次验证了分城市建模的必要性——不同城市之间存在系统性的定价差异，无法被房源特征所替代。

结论三：特征重要性排序与回归系数方向一致，验证了回归结论的稳健性。 面积在租房市场中重要性最高、核心区在两个市场中均具显著贡献、剩余产权年限具有独立解释力——这些发现与回归分析中各特征的边际效应方向完全一致，为前文的回归结论提供了额外的稳健性检验。

结论四：集成模型略优于单一模型，但差距有限。 随机森林与 XGBoost 的性能高度接近，简单平均集成仅在边际上有所提升，说明两种集成范式在本数据集上的表现趋于一致，预测结果具有稳健性。

8 总结与展望

8.1 研究工作总结

本研究以安居客平台杭州、金华、临沂三城市的二手房与租房数据为研究对象，围绕“城市住房市场价格形成与分化”这一核心问题，完成了从数据采集、清洗、特征工程到多维度建模分析的完整研究链路。三座城市分别代表高能级（杭州）、中等能级（金华）和低能级（临沂）的市场类型，为跨城市比较提供了天然的分层样本。

数据采集与清洗方面，本研究通过 Selenium 自动化爬虫获取了三个城市共计 52,579 条原始房源记录，经过去重、缺失值填充、字段标准化等七步清洗流程后，保留有效房源 44,077 条、有效小区 3,214 个。清洗后的数据在房源与小区两个维度上均保证了关键字段的完整性，为后续分析奠定了扎实的数据基础。清洗后的各城市房源数量分布为：杭州 18,560 条、金华 9,964 条、临沂 14,669 条。

特征工程方面，本研究将房源表与小区表通过 `community_id` 关联，派生房龄(`house_age`)、单价(`unit_price`)、租售比(`rent_sale_ratio`)和配套得分(`total_amenity_score`)等新特征，并按“城市 × 房源类型”组合独立输出完整数据表，为后续探索性分析、聚类、回归与预测提供了统一的数据输入。

探索性分析方面，本研究从小区和房源两个层面、十余个维度展开系统的描述性统计与可视化分析，并通过 Pearson 相关系数与单因素 ANOVA 揭示了变量间的关联强度与分类变量的解释力。研究发现，三城市在价格水平、面积结构、房龄分布、装修档次、配套资源等维度上均存在显著差异。城市间差异检验进一步从统计上证实了分城市建模的必要性——所有连续变量和分类变量的城市间差异均通过 1% 显著性检验。

聚类分析方面，本研究采用 K-Prototypes 算法对六个组合分别聚类，最优聚类数由轮廓系数确定。研究发现，杭州和临沂的二手房市场最优聚类数为 5，杭州租房为 5、临沂租房为 4，而金华二手房仅为 2、金华租房为 3，反映出低能级城市住房产品结构与价格梯度的相对单一性。聚类结果揭示了各城市内部“核心区高端改善—近郊刚需主体—远郊价格洼地”的空间分化格局，轮廓系数介于 0.276 至 0.366 之间，在房地产聚类研究中属于合理水平。

回归分析方面，本研究对六个组合分别建立多元线性回归模型，采用 HC3 稳健标准误处理异方差。模型测试 R^2 杭州最高（二手房 0.756，租房 0.743），临沂次之（二手房 0.712，租房 0.713），金华最低（二手房 0.520，租房 0.709）。研究发现，精装修溢价、房龄折价、区位溢价等核心特征的边际效应在不同城市间呈现系统性梯度差异——高能级城市的精装修溢价显著高于低能级城市，而低能级城市的房龄折价更大，反映出不同能级城市住房定价逻辑的本质差异。

预测分析方面，本研究构建了基于七个跨城市可比特征的全局预测模型，通过 Label Encoding 统一编码多分类变量，并引入剩余产权年限(`remaining_lease`)和核心区指示(`is_core`)两个新特征。随机森林与 XGBoost 两种模型在测试集上均取得良好表现，集成模型进一步提升预测精度。二手房测试 R^2 达到 0.796，租房测试 R^2 达到 0.865。特

征重要性分析表明，城市能级是最强的预测因子（二手房 0.865，租房 0.604），核心区和剩余产权年限亦具有独立贡献，验证了前述回归结论的稳健性。

8.2 研究问题解答

基于上述分析，本研究对引言中提出的四个子问题逐一回答如下：

子问题一（探索性分析）：不同能级城市的住房市场特征差异。三城市在价格分布、面积结构、房龄、装修程度、配套设施及租售比等方面呈现显著的分化特征。杭州价格中枢与离散度最高，金华次之，临沂最低；面积结构上，二手房市场金华、临沂大户型供给更充足，租赁市场户型小型化程度随城市能级提升而加剧；装修程度上，杭州精装修房源占比最高（78.3%），金华毛坯与豪华装修“两头高”的特征与其别墅供给充沛的市场结构一致；配套设施方面，公交、商超等基础配套三城覆盖率接近 100%，但轨道交通配套存在断崖式分化（杭州接近 90%，金华约 35%，临沂 0%），是区分三城区位价值的最核心变量。租售比（在租房源/在售房源）方面，杭州与临沂偏低（杭州 0.68，临沂 0.80，出租活跃），金华偏高（1.40，自住为主），表明不同能级城市在住房持有用途上存在显著的结构分化。城市间差异检验进一步证实，所有核心连续变量与分类变量在三城之间均呈现高度显著的差异（ $p < 0.001$ ），市场分化信号明确。

子问题二（回归分析）：各特征的边际贡献与城市间异质性。面积、楼层、装修、物业类型、房龄、区位等特征对房价和租金具有显著的边际贡献，且这些效应在不同城市间存在系统性差异。精装修溢价随城市能级递减——杭州租房精装修溢价高达 72.95%，杭州二手房为 20.20%，金华二手房为 14.12%，临沂二手房仅 4.49%，临沂租房市场中装修类别完全不显著。房龄折价随城市能级递增——临沂二手房房龄每增加一年单价下降 1.16%，杭州为 0.43%，金华房龄不显著；租房市场中，金华房龄折价最大（1.16%/年），临沂次之（0.70%/年），杭州最小（0.34%/年）。区位效应方面，行政区梯度在杭州最为陡峭（核心区与远郊单价差距达 61%），在金华明显减弱，与城市能级正相关。临沂商住楼呈现“租买分化”特征——二手房市场中商住楼单价显著低于普通住宅（-14.26%），但租房市场中商住楼租金显著高于普通住宅（+30.51%），可能源于商住楼小户型、核心地段的租赁优势与转售流动性较差的并存。

子问题三（聚类分析）：住房市场的结构性分群。各城市的住房市场均存在可辨识的结构性分群，但分群复杂度与城市能级正相关。杭州和临沂可划分为 4 至 5 个群体，金华仅 2 至 3 个。分群的主要驱动力为单价和行政区（空间区位），房龄和配套起修饰性作用，物业类型和装修在低能级城市区分度有限。不同城市聚类结构呈现“杭州多中心分化、金华单中心同质、临沂主城-新城双核”的梯度格局。租房市场聚类结构比二手房更为简化，主流群体占比更高（杭州租房 43.3% vs 杭州二手房 47.4%），同质化程度更高，反映租赁房源以中小户型普通住宅为主的供给特征，其多样性天然低于涵盖刚需、改善、豪宅等多层次的二手房市场。

子问题四（预测分析）：预测模型的有效性与特征重要性。基于七个跨城市可比的特征即可构建有效的房价/租金预测模型，二手房测试 $R^2 = 0.796$ ，租房测试 $R^2 = 0.865$ ，

说明抽象化后的特征集（剩余产权年限、核心区指示、城市能级编码等）成功保留了住房定价的核心信息。城市能级是最强的预测因子（二手房 0.865，租房 0.604），重要性显著高于房源个体特征，再次验证了分城市建模的必要性。核心区指示（`is_core`）在两个市场中均排名前列（二手房第 2，租房第 3），说明基于聚类结果将行政区抽象为“核心区/非核心区”的二值变量是有效的。剩余产权年限（`remaining_lease`）在两个市场中均排名第 4，说明土地使用权剩余期限对房价和租金均具有独立的边际解释力，验证了构造该特征的学术价值。特征重要性排序与回归系数方向一致，为前文的回归结论提供了稳健性检验。

8.3 研究局限与反思

任何实证研究都是在理想设计与现实约束之间折中的产物。本节对本研究中存在的客观局限进行坦诚说明，以帮助读者准确判断研究结论的适用边界。局限分为三类：**设计层面的调整与遗憾**（事后来看，有些决策可以做得更好）、**数据层面的硬约束**（本数据集无法支撑的分析方向）、以及**未来可能的扩展方向**。三类问题的区分有助于将本研究的贡献锚定在“已有数据的范围内能做多深”这一务实基点上。

8.3.1 设计层面的调整与遗憾

第一，“租售比”分析框架的调整。本研究在概念设计阶段将“租售比错配”设定为核心叙事线索，原计划从两个维度展开：供给端（在租房源/在售房源）和价格端（年租金/总价）。但在数据准备阶段发现，价格端租售比的计算面临样本不匹配问题——二手房与租房的数据虽是同一来源，但并非同房源的配对样本，也非同小区的完整配对。若在小区层面计算价格租售比，需要将同小区的二手房均价与租房均价进行匹配，但匹配后样本量损失较大。这一损失使匹配后的小区样本在结构上可能与完整样本存在差异（匹配成功的必要条件是該小区同时存在至少一条二手房和一条租房记录，而仅存在单侧房源的小区被排除）。为避免样本选择偏误对结论的干扰，本研究最终放弃了价格端租售比的计算，将分析口径调整为供给端租售比（`nrp/nsh`），从住房持有用途结构的角度回应城市间的分化差异。

第二，层次聚类方法的尝试与放弃。本研究在设计阶段决定同时采用 K-Prototypes 和基于 Gower 距离的层次聚类两种方法进行交叉验证。执行后发现，层次聚类在本数据上产生了极端不均衡的簇结构（一个背景簇占比超过 99.9%），且在不同链接方法下均无法改善。分析认为，层次聚类在样本量较大、数据分布连续且“平凡样本”占绝对主体的场景下，其贪心合并策略会将海量相似样本快速聚为一个巨型簇，而将少量与中心距离较远的极端值孤立出来——这在数学上是“正确”的（簇间距离大，轮廓系数高），但在业务上毫无意义。因此，层次聚类结果仅作为方法尝试在报告中简要呈现，未作为主要结论依据。

8.3.2 数据层面的硬约束

第三，挂牌价与成交价的偏差。本研究使用的价格为安居客平台挂牌价，而非实际成交价。这是本数据集最根本的限制——挂牌价反映的是业主的心理预期，而非市场的真实成交水平。不同城市、不同房源类型的议价空间差异较大，且本研究无法获取任何成交价锚定数据来进行校正。因此，所有回归系数均应理解为“对挂牌价的边际贡献”，而非“对成交价的边际贡献”。这一偏差对高能级城市（议价空间相对较小）的影响可能小于低能级城市（议价空间更大），在跨城市比较时需要特别注意。

第四，配套质量信息的缺失与尝试。本研究对周边配套设施的处理仅限于数量维度（如 `around_学校_count`），未能区分配套的质量等级。这一局限并非我们没有意识到，而是源于一次规模超出预期的尝试。

在研究设计阶段，我们曾计划对学校的质量进行分级标注。以杭州为例，我们首先将“幼儿园、小学、初中、高中、大学”分别区分开来，计划只保留小学与初中（因这两类与学区房溢价直接相关），并尝试参照杭州市教育局公布的“重点学校”名单进行标注。但在实际执行中，仅“小学”一类就涉及超过 300 所学校，且需要逐校核实其是否为“省重点”“市重点”或普通小学，同时还需要区分公办与民办——因为公办小学与房价挂钩，而民办小学通常不参与学区划片。我们花费了近两周时间完成了杭州小学的初步标注，但当准备将同样流程扩展到金华和临沂时，发现金华和临沂的教育局官网并未公布类似的“重点学校”分级体系，两座城市的名校效应更多依赖本地家长的口碑积累，而非官方的等级划分。这意味着不同城市之间的学校质量标签不可比——杭州的“区重点”与临沂的“口碑好校”无法在同一框架下进行编码。最终，因跨城市标准化的不可行性，以及手动标注工作量超出了本研究的可行范围，我们放弃了配套质量维度的纳入，退回到数量维度的处理方式。

医院配套面临同样的问题。我们曾尝试将医院分为“三甲、三乙、二甲、社区医院”四个等级，并按照杭州市卫健委的医院名录进行标注。杭州的医院等级信息相对完整，但临沂部分县级医院在公开渠道中难以查明确切的等级信息，金华同样存在类似问题。最终，这部分工作因跨城市数据不可比而暂停。

第五，时间维度的截面限制与尝试。本研究使用的数据为截面数据，仅反映了某一时点的市场状态。需要说明的是，我们并非没有考虑时序分析的可能性——安居客房源详情页中实际存在“今日房价变化”这一字段，显示该房源相比前一天的挂牌价涨跌幅度，理论上可以通过连续多日爬取积累时间序列数据。但在实际爬取过程中，该字段的获取面临两个问题：一是该字段仅出现在部分房源的详情页中（约 60% 的房源显示该信息），缺失率较高；二是反爬机制对高频访问的限制使得我们无法对同一套房源进行连续多日的高频跟踪。我们曾尝试对杭州 100 套样本房源进行为期一周的每日爬取测试，结果显示仅有约 40% 的房源能够获得完整的 7 日连续数据，样本流失严重。由于无法保证时序数据的完整性和代表性，本研究放弃了时间序列分析，仅以截面数据完成当前分析。

第六，物业费、容积率、绿化率等小区品质指标的缺失。数据清洗阶段虽然保留了

物业费、容积率、绿化率等字段，但缺失率较高：绿化率缺失约 18%，容积率缺失约 22%，物业费缺失约 35%。更关键的是，缺失模式并非完全随机——品质越高的小区信息越完整，新建小区的字段填充率显著高于老旧小区。这意味着，无论是直接剔除缺失样本还是中位数插补，都会引入系统性偏差：前者会偏向高品质小区，后者则会人为压缩高品质与低品质小区之间的差异。我们曾尝试基于建筑年代和物业类型对缺失值进行回归插补，但插补后的变量与真实值之间的偏差无法验证，且插补过程本身引入了额外的模型假设，可能使后续回归分析的标准误被低估。权衡之下，我们选择将这些字段暂不纳入建模，并在所有相关分析中承认“小区品质溢价”这一维度的缺失。

第七，商圈与地理空间信息的利用困难。小区表中的商圈(business_circle)和详细地址(location)字段包含了丰富的地理空间信息，但本研究中仅通过行政区(district)的虚拟变量间接反映了区位差异。我们曾尝试利用高德地图的逆地理编码 API 将小区地址转换为经纬度坐标，以计算小区到城市中心、最近地铁站、最近商圈的实际距离。但在测试中发现，三个城市的地址文本格式存在较大差异——杭州的地址通常包含“XX 路 XX 号”的完整门牌信息，而临沂的部分小区地址仅包含“XX 街道 XX 村”等模糊描述，地址解析的成功率在不同城市之间相差悬殊（杭州约 85%，临沂仅约 55%）。地址解析失败的小区在地理分布上并非随机，而是集中在城市边缘区域和新建小区，若仅保留解析成功的样本，将导致空间样本结构失衡。此外，商圈边界的确权也存在争议——杭州的“武林商圈”与“钱江新城商圈”存在明确的行政边界，而临沂的“人民广场商圈”边界模糊，不同来源的商圈定义不一致。这些困难使得地理空间信息的利用在当前阶段难以落地，留待后续研究借助更成熟的 GIS 工具链进一步探索。

8.3.3 对研究设计的反思与改进方向

上述局限不仅是本研究的“减分项”，也为我们提供了值得反思的经验。在完成本研究的全部分析后，我们意识到以下几个“如果重新设计，可能会做得不同”的判断：

第一，城市间标准化框架的缺失。本研究中多次遇到的“跨城市不可比”问题（学校等级、商圈边界、医院等级等），本质上是缺乏一个统一的多城市特征标准化框架。如果未来研究能够为每个城市分别构建配套质量词典（如杭州的名校列表、临沂的口碑学校列表），并以“是否为该城市前 10% 优质配套”的二值变量而非绝对等级进行编码，或许可以绕过“城市间不可比”的障碍。这一思路值得在后续研究中探索。

第二，特征选择策略的反思。本研究在特征工程阶段对配套、品质、空间等维度采取了“广撒网”策略，试图将尽可能多的字段纳入分析。但事后来看，这种策略导致了大量字段因缺失率高或标准化困难而被搁置，投入了收集和清洗成本却未能产生分析价值。如果重新设计，我们可能会选择性地针对少数几个核心特征进行深挖（如仅聚焦于行政区、房龄、装修、物业类型的组合），而非追求字段数量的全面性。这一经验教训对同类研究具有一定的参考价值。

第三，时序数据收集的可行性再评估。虽然本研究因数据获取困难未能完成时间序列分析，但“今日房价变化”字段的的存在表明，安居客平台具备支持时序分析的数据潜

力。未来研究可尝试设计更合理的爬取策略（如降低频率、增加 IP 代理池），或与平台合作获取脱敏的历史数据，以突破当前截面数据的局限。

8.3.4 未来可能的扩展方向

上述局限为后续研究提供了明确的改进路径：

第一，成交数据的获取。若能通过其他渠道获取实际成交价格（如各地住建部门公示的网签数据、或贝壳平台的成交记录），可从根本上解决挂牌价偏差问题，并进一步开展价格端租售比的跨城市比较，这将是本研究最直接的延伸方向。

第二，多源数据融合。可整合教育部门学校评级、卫健委医院等级等外部数据，构建精细化的配套质量指标。对于跨城市不可比的问题，可采用“城市内相对排名”而非绝对等级进行编码，以保持城市间的可比性。

第三，地理信息系统（GIS）方法的引入。随着地址解析工具和地理信息数据的成熟，未来研究可更精确地计算小区到城市各核心功能区的实际距离，替代行政区的虚拟变量，更准确地捕捉区位价值的空间衰减规律。

第四，面板数据的积累与分析。通过持续爬取建立时间序列数据集，可引入时间固定效应模型控制宏观因素，更精确地识别各特征的因果效应，并分析不同城市房价的时序动态差异。

第五，预测模型的可解释性增强。可引入 SHAP 值分析，进一步揭示各特征对单个样本预测的具体贡献方向与幅度，实现“精度”与“可解释性”的更好平衡，提升非线性模型在房地产估值实务中的可用性。

综上，本研究在数据质量、特征维度和方法选择上虽有不足，但这些局限的识别与讨论也为后续研究提供了明确的改进方向。诚实面对局限，是本研究的学术底线。我们相信，明确标出“已知的未知”，比刻意掩盖数据缺陷、营造完美研究的假象，对学术共同体的贡献更大。